

UNIVERSITATEA BABEȘ-BOLYAI CLUJ-NAPOCA
FACULTATEA DE MATEMATICĂ ȘI INFORMATICĂ
SPECIALIZAREA INFORMATICĂ

LUCRARE DE LICENȚĂ

Generarea procedurală a nivelelor
în jocuri folosind rețele neuronale recurente

Conducător științific

Asistent Mircea Ioan-Gabriel

Absolvent

Ivanov Silviu-Gabriel

2018

Cuprins

Introducere.....	3
1. Generare procedurală de conținut.....	4
1.1. Generarea procedurală de conținut în jocurile video.....	5
1.2. Cazuri de utilizare pentru PCG.....	7
2. Inteligența artificială.....	8
2.1. Machine Learning.....	10
2.2. Rețele neuronale artificiale.....	11
2.3. Rețele neuronale recursive.....	12
2.4. LSTM.....	13
2.4.1. Descriere	13
2.4.2. Modul de funcționare.....	14
3. Benchmarks	15
3.1. Reprezentare secvențială	15
3.2. Reprezentare sub formă de grilă.....	17
3.3. Reprezentare folosind grafuri	20
3.4. Observații și concluzii	21
4. Aplicație.....	22
4.1. Specificarea problemei	22
4.2. Lode Runner	23
4.3. Dezvoltarea aplicației	24
4.3.1. Analiza cerințelor.....	25
4.3.2. Proiectarea aplicației.....	28
4.3.3. Tehnologii folosite.....	31
4.3.3. Implementare	34
4.3.4. Testare.....	41
5. Rezultate obținute	42
Concluzii.....	44
Lista figurilor	45
Bibliografie.....	47

Introducere

Generarea procedurală în cadrul jocurilor reprezintă o metodă de a crea conținut precum nivele, texturi sau caractere fără a fi nevoie de contribuție umană. Această procedură a fost folosită în jocuri încă de la începutul anilor '80. O problemă generală a acestei metode o reprezintă diversitate. Este important să găsim un grad ridicat de diversitate între nivele, dar și în cadrul acestora. Un nivel unde jucătorul trebuie să sară peste un obstacol de prea multe ori, devine la un moment dat plictisitor. Un alt caz al lipsei de diversitate este prezent atunci când singura diferență dintre două sau mai multe nivele o reprezintă gama diferită de culori. Totodată, nu dorim ca generarea nivelului să fie complet aleatorie și jocul să nu poată fi finalizat. Astfel trebuie să găsim calea de mijloc dintre aceste două extreme.

Procesul generării de conținut prezintă soluții multiple ce variază de la crearea unei gramatici și a unui set de reguli până la stabilirea unor modele ce vor fi controlate de un set de variabile. Dezavantajul acestor abordări îl reprezintă timpul necesar pentru stabilirea și dezvoltarea acestor reguli.

Astfel se naște întrebarea, putem genera conținut folosind tehnici de învățare, și pot acestea să îmbunătățească generarea procedurală de conținut în jocuri? Modelul necesar generării de conținut poate fi de foarte multe feluri datorită multitudinii de abordări existente în ceea ce privește acest domeniu. Se găsește cu siguranță potențial în rețelele neuronale recurente ce sunt deja capabile să genereze text coerent. Cu ajutorul acestora și a tehnicilor implicate în machine learning vom putea fi capabili să construim nivele ce par create de om. Rezultatul la care ne așteptăm este un model ce este capabil să folosească ca și date de antrenament nivele originale ale jocurilor, ca mai apoi să poată genera nivele de unul singur.

Datorită faptului că rețelele neuronale recurente de tip LSTM reprezintă cea mai bună alegere pentru învățare secvențială, iar nivelele pe care ne vom axa în cadrul acestei lucrări vor fi de tip platformă, vom lua în considerare folosirea acestora ca și metodă de învățare și generarea a conținutului.

Scopul final al acestei lucrări va fi analiza rezultatelor obținute precum și menționarea unor observații pe baza acestora. De asemenea, dorim ca nivelele generate să poată fi puse în practică și să găsim o modalitatea de a le testa, cu scopul de observa dacă acestea pot fi completate sau nu.

1. Generare procedurală de conținut

Generarea procedurală de conținut reprezintă o metodă prin care putem să generăm date folosind un algoritm. În decursul anilor importanța **PCG**¹ pentru dezvoltarea jocurilor, dar și pentru toate tipurile de conținut a crescut considerabil, numărul de cercetări în legătură cu acest domeniu s-a mărit, încercând să se descopere moduri noi de a genera conținut de înaltă calitate și dând la o parte intervenția umană.

Această metodă este foarte răspândită în toate domeniile de activitate, putând fi generate imagini, muzică precum și obiecte 3D, o importanță puternică având de asemenea și în cadrul sintetizării vocale. Reprezentând o metodă artificială ce este capabilă să reproducă discursul uman, sintetizarea vocală joacă un rol important în multe sisteme precum: Apple², AmigaOS, Microsoft Windows, Atari etc.

Câteva avantaje ce sunt prezente în momentul în care generăm conținut procedural sunt: minimizarea spațiului necesar de stocare a datelor, posibilitatea de a crea un volum considerabil de conținut și abilitatea de a avea o nouă perspectivă asupra întregului produs final.

¹ Procedural Content Generation

² Apple a avut primul sistem de operare ce conținea sintetizare vocală.

1.1. Generarea procedurală de conținut în jocurile video

În decursul anilor PCG în jocuri s-a dezvoltat foarte mult, utilizând domeniul programării de jocuri și cercetările tehnice. Valoarea pe care o aduce este reprezentată de către reducerea costului și a efortului de producție, economisirea spațiului necesar pentru stocarea datelor precum și crearea unui design inovator. Câțiva cercetători academici din domeniul PCG au luat în considerare această provocare și de asemenea au analizat cum generarea de conținut într-un mod procedural poate să confere noi experiențe jucătorului și să se adapteze pe placul acestuia. Construind un model formal ei au reușit să modeleze creativitatea computațională și să sporească înțelegerea noastră față de designul jocului [1].

Multe dintre aplicabilitățile „constructive” ale PCG în industria de jocuri, sunt reprezentate de către algoritmi bazați pe zgomot sau gramatici, cu scopul de a crea într-un mod continuu conținut fără a fi necesară o evaluare ulterioară, în timp ce alții se axează pe metode bazate pe rezolvare [2] sau căutare [3]. Toate aceste metode care generează conținut au în comun parametri, constrângeri, algoritmi și obiective create de către proiectanți și cercetători. Chiar dacă noi ne putem inspira din jocul actual, aceste metode bazate pe **AI**³ sunt foarte rar folosite pentru a genera conținut singure. Conținutul ce va fi generat poate aparține oricărui tip din cadrul jocului, de la obiecte din inventar, modelele caracterelor și mediul înconjurător până la misiuni, reguli și arme.

Trebuie menționat că în cadrul acestei lucrări ne vom concentra atenția asupra părților **funcționale**⁴ ale jocului, și nu pe design sau partea artistică a acestuia. Un exemplu de conținut ce va fi exclus îl reprezintă atributele cosmetice ale diferitelor obiecte deoarece ele nu afectează într-un mod direct acțiunile jucătorului. De asemenea trebuie precizate diferențele cheie între generarea procedurală de conținut în general, în toate domeniile și PCG în jocuri. În timp ce în alte arii de cercetare ale PCG avem posibilitatea de a crea orice tip de conținut fără a fi constrânși în vreun fel, în ceea ce privește aria jocurilor suntem strict limitați modul în care funcționează jocul și regulile acestuia – *ergodic*⁵ *media* [4]. Un nivel ce conține o structură sau un număr de inamici

³ Artificial Intelligence

⁴ Prin conținut funcțional ne referim la modificări care vor avea un efect sporit asupra experienței jucătorului.

⁵ Literatura ergodică necesită un efort netrivial pentru a da posibilitatea cititorului să traverseze textul.

ce conduc jucătorul către o fundătură, sau fac imposibilă finalizarea nivelului, nu sunt acceptabile, chiar dacă aranjamentul noului conținut este nou și atractiv acesta va conduce la experiența negativă a jucătorului și va fi chiar mai rău decât un nivel care este terminabil dar este creat de la început și stocat în memorie. De exemplu *Figura 1* reprezintă un labirint în care se poate doar intra, nu și ieși, un astfel de rezultat cu siguranță ar conduce la o experiență neplăcută a jucătorului.




Figura 1 - Labirint fără ieșire

Desigur că vor exista mereu provocări și în cadrul celorlalte domenii ce nu au legătură cu jocurile, provocări ce vor avea atașate asupra lor tot felul de constrângeri cum ar fi: a crea o imagine ce pare a fi reală; totuși în această lucrare ne vom concentra doar pe ce este din domeniul jocurilor.

Unul dintre pionierii acestui domeniu este *Dwarf Fortress*, un joc în cadrul căruia este simulată construcția și managementul unei fortărețe. Grafica jocului este bazată pe text, jocul neavând un sfârșit sau un obiectiv principal ce trebuie îndeplinit. Un atu important al acestui joc îl constituie modul în care lumea este generată. Procesul implică generarea procedurală a elementelor de bază precum circuitul de drenare, temperatura, distribuția mineralelor, elevația și ploaia. În *Figura 2* se observă modul în care harta este generată, fiecare joc începând cu acest proces. După câteva minute lumea este populată și istoria începe să se creeze în funcție de parametrii aleși [5].




Figura 2 - Exemplu de generare a lumii în Dwarf Fortress [6]

1.2. Cazuri de utilizare pentru PCG

În cadrul acestui capitol vom analiza câteva întrebări ale generării procedurale de conținut. Ne vom axa pe avantajele funcționale dar și pe cele economice ale acestei metode.

A) *Comprimarea datelor*

Una dintre primele motivații ale implementării PCG în primele jocuri, dar valabilă și astăzi în jocurile moderne a fost necesitatea comprimării spațiului necesar de stocare a datelor. Neavând suficient spațiu pe disk pentru a putea salva toate nivelele necesare sau toate hărțile unui joc, adăugând faptul că unele jocuri au loc în universuri vaste, producătorii au avut nevoie de o modalitate de a putea genera surplusul de date pentru a fi mai departe trimise către jucător. Jocuri precum *No Man's Sky* [7] ce se desfășoară într-un univers aproape nelimitat, ar fi imposibile de salvat pe disk, astfel dezvoltatorii au folosit PCG pentru a crea plante și animale, salvând pe disk doar date absolut necesare precum proprietăți și caracteristici ale mediului înconjurător. În *Figura 3* putem observa cum dintr-un model de bază sunt generate modele altor animale din cadrul jocului.



Figura 3- Modele de animale din No Man's Sky

B) *Cooperare în creativitate și design*

Alt factor important în procesul de dezvoltare a jocurilor este reprezentat de către design. Generarea procedurală folosind *Machine Learning* poate ajuta un designer uman să creeze un conținut mult mai inedit. Partea „co-creativă”⁶ vine din faptul că cel ce proiectează poate antrena un model punându-i la dispoziție exemple din domeniul respectiv. Procedura poate reduce drastic timpul dedicat pentru antrenarea creatorului, de asemenea poate micșora gradul necesar de pregătire pentru acesta deoarece va avea mult mai puțină treabă de făcut. Totodată bugetul proiectului va fi redus, deoarece numărul necesar de angajați va fi redus considerabil. În cele din urmă, PCGML⁷ poate fi folosit și pentru auto-completarea nivelelor și a conținutului ce a fost specificat doar parțial de către dezvoltator, dar nu încă finalizat.

⁶ Co-creație reprezintă o strategie prin care diferite entități participă în procesul de creație cu scopul de a o face împreună mai bine decât ar face-o fiecare pe cont propriu.

⁷ Procedural Content Generation using Machine Learning

C) *Reparare*

O altă funcționalitate pe care PCGML o oferă este posibilitatea de a identifica și repara zonele care nu sunt jucabile sau a oferi sugestii cum ar putea fi reparate. O metodă folosită adeseori o reprezintă cea a **autoencoderilor**⁸ capabili să refacă și să repara porțiuni din conținut precum și segmente corupte. În *Figura 4* ce aparține unei cercetări cu privire la repararea imaginilor [8] se observă cum diferite abordări reușesc să **rafineze** și să clarifice o porțiune din imagine.

D) *Analiză și evaluare*

Principala diferență între **PCGML** și **PCG** o reprezintă capacitatea de a recunoaște, evalua și analiza conținutul jocului. Creând un model bazat pe nivelele originale ale un joc specific, sau pe conținutul original, modelul va putea mai târziu să identifice conținutul ce a fost creat de către un algoritm față de cel creat de către un proiectant sau un jucător.

E) *Generare autonomă*

Ultimul dar nu cel din urmă caz de utilizare a PCG este posibilitatea de a crea în mod continuu conținut fără a fi nevoie de interacțiune umană. Această funcționalitate este adeseori întâlnită în mai toate câmpurile de cercetare în ceea ce privește inteligența artificială. Generarea autonomă conferă posibilitatea de crea și oferi conținut **online**⁹. Este de dorit pentru un joc să poată genera conținut în timp ce rulează, fără a fi nevoie de o ajustările unei persoane sau de încărcarea nivelului/hărții/conținutului de pe disk.



Figura 4- Clarificarea unui segment al imaginii [8]

⁸ Rețea neuronală artificială folosită pentru a învăța un model o modalitate eficientă de comprimare a datelor.

⁹ Acumularea informațiilor și prelucrarea lor în același timp care altcineva interacționează cu ele și le modifică.

2. Inteligența artificială

Inteligența artificială sau AI reprezintă un domeniu de studiu în cadrul căruia se încearcă înțelegerea entităților inteligente. AI momentan cuprinde o varietate de subdomenii, de la cerințe specifice precum jocul de șah, scriere de poezii, diagnosticarea bolilor sau demonstrarea teoremelor matematice până la zone mult mai generale precum percepția și raționamentul logic. Adeseori oamenii de știință din cadrul acestui domeniu vast tind să-și aplice metodele și algoritmii în orice altă zonă care necesită efort intelectual uman, demonstrând astfel universalitatea aplicabilității acestui domeniu [9].

Ce înseamnă a fi inteligent și cum putem noi testa acest lucru? Propus în anul 1950 de către Alan Turing¹⁰, test ce îi poartă și numele, „*The Turing Test*” a fost conceput pentru a aduce o definiție satisfăcătoare a inteligenței computaționale. Testul constă în capacitatea calculatorului de a atinge performanțe cognitive umane cu scopul de a fi capabil să inducă în eroare un interogator uman. Câteva capacități necesare ale computerului pentru a trece cu succes acest test ar fi: *procesarea naturală a limbajului*, să comunice și să stăpânească cu desăvârșire o anumită limbă; *reprezentarea informațiilor*, capacitatea de a stoca informații în timpul unei interogări; *machine learning*, să se adapteze noilor circumstanțe și în cele din urmă *raționament automat*, să fie capabil să folosească informațiile stocate pentru a trage noi concluzii sau să răspundă la întrebări.




Figura 5 - Google Duplex

Figura 5 face parte din cadrul prezentării Google din data de 8 Mai 2018, unde s-a prezentat o nouă tehnologie numită „*Google Duplex*” capabilă să întrețină conversații sofisticate într-o manieră complet autonomă, cu scopul de a crea o rezervare. Deși se recunoaște că sistemul nu poate finaliza autonom rezervări ce au un grad ridicat de dificultate,

din punctul meu de vedere această tehnologie se află printre primele care sunt capabile să treacă testul turing într-o conversație naturală.

¹⁰ Personalitate de mare influență în domeniul informaticii, fost matematician, logician și filosof, reprezintă unul dintre părinții inteligenței artificiale.

2.1. Machine Learning

Machine Learning reprezintă adeseori modificările aduse unui sistem ce se ocupa cu îndeplinirea unor cerințe din domeniul inteligenței artificiale. Deși sistem AI se ocupă cu observarea și modelarea mediului înconjurător cu scopul de a determina acțiunile corecte ce trebuiesc făcute într-un mod autonom fără a fi nevoie de interacțiune din exterior, nu înseamnă neapărat ca acesta este inteligent [10]. Vom analiza în ceea ce urmează cum ajustarea câtorva componente ale acestui „*agent*” sunt necesare în anumite situații pentru ca acesta să poată fi numit inteligent.

- Posibilitatea de a se adapta la tot ce apare nou. Cum lumea este într-o continuă mișcare și evoluție nu ar fi practic să trebuiască să adaptăm și să remodelăm de fiecare dată sistemul, astfel, implementarea machine learning-ului devine foarte utilă pentru a face față fluxului continuu de modificări.
- Am dori ca „*agentul*” să fie capabil să-și ajusteze singur structura internă pentru a ajunge la rezultatul dorit, în funcție de exemplele pe care i le furnizăm. Astfel, într-un număr relativ mare de iterații și de exemple procesate acesta este capabil să se apropie foarte mult de rezultat, chiar dacă datele de intrare sunt noi pentru acesta.
- De multe ori se întâmplă ca mașinăriile dezvoltate să nu aibă o structură potrivită pentru mediul în care activează fie din cauza unor greșeli logice, fie funcționale. În această privință se pot folosi diverse metode din cadrul machine learning-ului pentru a ajuta la designul acestor mașinării.

Astăzi interesul pentru domeniul machine learning-ului este într-o continuă creștere, în mare parte el se datorează nevoii de a crea modele capabile să folosească seturi de date deja existente pentru a se antrena. Una dintre cele mai comune abordări o reprezintă folosirea de *DNN*¹¹ în cadrul *Deep Learning*-ului [11], acesta fiind potrivit pentru o varietate de sarcini unele dintre ele fiind chiar și generarea de conținut precum: imagini, videoclipuri și înregistrări audio.

¹¹ Deep Neural Network

2.2. Rețele neuronale artificiale

Considerăm o rețea neuronală artificială ca fiind un model simplificat al structurii rețelei neuronale biologice. Un ANN^{12} este format din unități de procesare interconectate. Modelul general al acestor unități de procesare este format dintr-o componentă de însumare și una de returnare a rezultatului [12]. Componenta ce are ca scop însumarea primește N valori ca și date de intrare, după care atribuie fiecăreia dintre ele câte o greutate și în cele din urmă calculează suma lor. A

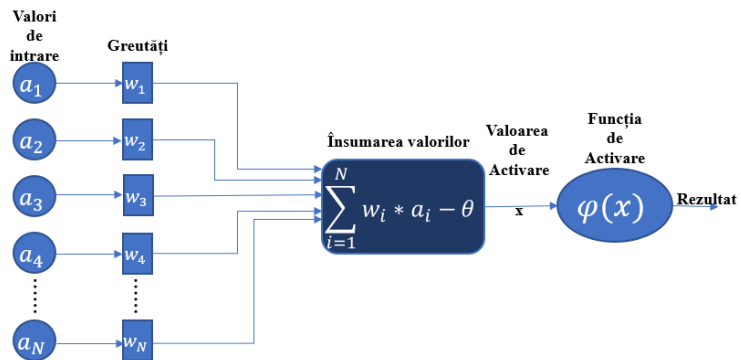


Figura 6 - Modelul perceptronului unui neuron

doua componentă ia această *valoare de activare* și o returnează sub forma unui *semnal*. În funcție de semnul pe care îl are fiecare greutate se poate spune dacă acel input este *excitator* sau *inhibitor* [13]. De asemenea, inputurile și outputurile pot fi discrete sau continue. În Figura 6 se poate observa modul de funcționare a unui neuron. Acești neuroni sunt grupați pe straturi, rețeaua fiind formată dintr-unul sau mai multe straturi conectate între ele. În cele mai multe cazuri rețeaua conține un strat de intrare, unul de ieșire și câteva straturi între cele două numite straturi *ascunse*.

Una dintre cele mai populare metode de învățare este reprezentată de *backpropagation*. Acest proces implică propagarea erorilor înapoi plecând de la stratul de ieșire către straturile ascunse cu scopul de a recalcula greutatea pentru unitățile de procesare din cadrul acestor straturi. Eroarea este calculată folosind diferența între rezultatul dorit și rezultatul obținut pentru fiecare unitate de ieșire.

Cea mai simplă rețea neuronală este cea în care neuronii de pe un strat comunică doar cu cei de pe stratul următor (*feedforward*), informația călătorind de la intrare spre ieșire. Tot foarte populară este și rețeaua neuronală recursivă, unde datele merg în mai multe direcții. Această rețea posedă o abilitate ridicată de învățare fiind adeseori folosită pentru scopuri mult mai complexe cum ar fi învățarea scrisului de mână sau chiar recunoașterea vocală.

¹² Artificial Neural Network

2.3. Rețele neuronale recursive

Rețeaua neuronală recursivă este un tip de rețea neuronală artificială care operează cu structuri secvențiale de date. De obicei, într-un ANN datele de input și cele de output sunt independente una față de cealaltă, dar în cazul multor situații acesta nu este un comportament dorit. De exemplu dacă dorim să deducem următorul cuvânt dintr-o secvență de cuvinte este necesar să ținem cont de cuvintele care au fost înainte. RNN sunt *recurente* deoarece ele execută aceeași operație pentru toate elementele dintr-o secvență, având output-ul dependent față de calculele anterioare. O altă metodă prin care putem descrie RNN este să spunem că acestea deține o „memorie” ce înregistrează informațiile calculate până la o anumită unitate de timp [14].




Figura 7- Rețea neuronală recursivă desfășurată [15]

În Figura 7 se poate observa o rețea neuronală recursivă simplă desfășurată în funcție de momentul la care s-a procesat fiecare input. Dacă am fi studiat de exemplu predicția unui cuvânt și am fi avut cate o propoziție de 10 cuvinte, rețeaua ar fi putut fi reprezentată desfășurată în 10 straturi, câte un strat pentru fiecare cuvânt. În cele ce urmează vom explica notațiile de mai sus precum și câteva formule specifice acestei structuri:

- s_t reprezintă starea interioară a rețelei la un anumit pas t ; reprezintă „*memoria*” rețelei, el este calculat în funcție de starea anterioară și input-ul curent $s_t = f(Ux_t + Ws_{t-1})$. Funcția f este adeseori o funcție non-liniară precum *ReLU* sau *tanh*.
- x_t reprezintă data de intrare la un anumit moment t .
- o_t reprezintă output-ul la un anumit moment t . De exemplu, dacă am dori să prezicem următorul cuvânt într-o propoziție acest output ar reprezenta un vector de probabilități pentru fiecare literă din alfabet. $o_t = \text{softmax}(Vs_t)$

2.4. LSTM




Figura 8 - RNN desfășurat [29]

Ne punem întrebarea dacă, este îndeajuns să avem acces la un număr finit de momente anterioare pentru a putea determina cu succes pe următorul. Răspunsul este că depinde. Câteodată ne este îndeajuns să ne uităm la datele recente pentru

a putea procesa cu succes task-ul curent. De exemplu: dacă dorim să prezicem ultimul cuvânt în „culoarea sângelui este *roșie*”, nu avem nevoie de mai multe informații decât cele pe care le deținem deja din contextul curent – este destul de evident, cuvântul căutat este „*roșie*”. În aceste cazuri în care informația căutată se află la mică distanță de informația relevantă nu avem nevoie de o structură mai complexă decât un RNN. Dar, sunt și cazuri în care cantitatea de context necesară este mult mai mare. Să considerăm că rețeaua noastră trebuie să prezică ultimul cuvânt din următorul text „La vârsta de 8 ani m-am mutat împreună cu ai mei în China ... am reușit să ne înțelegem deoarece vorbeam fluid *chineză*”. Informația anterioară sugerează că urmează numele unei limbi, dar pentru a ne da seama avem nevoie de informații ce se află cu mult în urmă. Din păcate, cu cât diferența între informațiile relevante și informația curentă se mărește, posibilitatea ca RNN să reușească să conecteze informațiile între ele cu succes, scade drastic [16].

2.4.1. Descriere

Rețelele **LSTM** sunt o clasă a RNN capabile să învețe dependențe de lungă durată. Toate rețelele neuronale recurente au forma unor module ce par fi legate ca și un lanț (Figura 8) . Deși rețelele LSTM




Figura 9 - Rețea LSTM desfășurată [29]

moștenesc această structură inter modulară, ele vin cu ceva nou în ceea ce privește structura internă

a fiecărui modul. În loc de o rețea neuronală cu o singură funcție de activare, LSTM conține patru funcții ce comunică între ele, fiecare având un scop bine definit (Figura 9).

2.4.2. Modul de funcționare

În *Figura 9* fiecare linie reprezintă un vector de valori, călătorind de la input-ul unui nod până la output-ul acestuia și input-ul următorului nod. Cercurile cu roz reprezintă operații pe vectori și dreptunghiurile galbene simbolizează straturi neuronale. Starea internă a celulei este reprezentată de linia din partea superioară, la ea se adaugă sau se șterg informații la trecerea prin porți.

1. **Uitarea** – primul pas îl reprezintă filtrarea informațiilor din starea celulei. Decizia se face pe baza unui strat cu o funcție de activare sigmoidală ce calculează un număr între 0 și 1 pentru fiecare element din vectorul de stare al celulei. (0 – uită elementul, 1 – reține elementul). $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$
2. **Memorarea** – al doilea pas constă în adăugarea noilor informații în starea celulei. Acest proces este format din două părți. Primul strat cu activare sigmoidală decide ce valori vom actualiza în starea curentă, în timp ce al doilea strat cu activare \tanh ¹³ pregătește noi candidați ce ar putea fi adăugați. Rezultatele formează vectorul ce va actualiza starea internă. $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i); \tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$
3. **Actualizarea stării celulei** – al treilea pas constă în actualizarea celulei folosind valorile de la pașii anteriori. Înmulțim rezultatul de la pasul 1 cu starea curentă a celulei pentru a decide ce vom uita, după care adăugăm produsul valorilor de la pasul 2 pentru a memora noua informație și a o actualiza pe cea veche. $C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$
4. **Returnarea rezultatului** – ultimul pas îl constituie calcularea și returnarea rezultatului. Primul strat cu activare sigmoidală decide ce elemente din starea internă a celulei vom returna, în timp ce al doilea strat cu activare \tanh pregătește elementele din starea internă a celulei, aducându-le între valorile 0 și 1. La final cele două rezultate se înmulțesc între ele. $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o); h_t = o_t * \tanh(C_t)$

¹³ Funcție tangentă hiperbolică cu proprietatea că rezultatul ei se află în intervalul (-1,1). Este adeseori folosită ca și funcție de activare.

3. Benchmarks

Deoarece analiza și compararea rezultatelor în ceea ce privește generarea de conținut în jocuri se rezumă de multe ori la subiectivism, vom analiza cele mai bune tehnici folosite în PGML din literatură, grupându-le în funcție de modul de reprezentare a datelor precum și metoda de antrenare aleasă.

Metoda de antrenare

Se vor lua în considerare câteva tehnici din machine learning potrivite pentru crearea și antrenarea unui model ce va fi ulterior folosit pentru generarea conținutului în jocuri, acestea sunt : *factorizarea matricelor, maximizarea așteptărilor, numărarea frecvențelor și propagarea înapoi.*

Reprezentarea datelor

Fiecare nivel/hartă/element va fi reprezentat într-o manieră ce facilitează metoda de antrenare aleasă, acestea fiind: *grilă, secvențial și graf.* Este posibil ca pentru același tip de joc să avem mai multe reprezentări. Analizând fiecare mod posibil de a reprezenta datele, putem observa și compara principalele diferențe, astfel înțelegând îmbunătățirile pe care le aduce fiecare metodologie.

3.1. Reprezentare secvențială

Fiind una dintre cele mai populare metode de a reprezenta conținutul unui joc de tip platformă. Un joc potrivit pentru această secțiune este „*Super Mario Bros*” [17] (*Figura 10*). De asemenea, oricare alt joc al cărui conținut ajunge la utilizator într-un mod secvențial este o alegere bună.



Figura 10 - Super Mario Bros publicat în 13 septembrie 1985 de către Nintendo Creative Department

i) Numărarea frecvențelor

Se referă la o metoda ce constă în împărțirea secvențelor în elemente atomice calculând frecvența acestora și determinând următorul element bazându-se pe probabilități pornind de la starea curentă. Cele mai eficiente tehnici ce sunt capabile să învețe probabilități condiționate și sunt adeseori folosite în domeniul machine learning-ului sunt

lanțurile Markov¹⁴. Fiecare stare conține multiple stări anterioare prin crearea secvențelor de tip *n*-grams¹⁵. Un articol ce se focusează pe problema creării și antrenării unui model bazat pe *n*-grams, utilizând nivelele originale din „Super Mario Bros”, este scris de către Dahlskog ș.a. , el




Figura 11 – 1,2,3-grams [18]

reușind să genereze astfel noi nivele [18]. Procesul de antrenare folosea diferite valori ale lui *n*, iar în timpul generării puteam observa că pentru 1-grams avem un nivel generat aproape aleatoriu, în timp ce 2-grams și 3-grams se apropie mai mult de un nivel real (Figura 11).

ii) Propagarea înapoi

Încă de la începuturile PCGML pentru dezvoltatori rețelele neuronale artificiale au reprezentat funcția universală cu ajutorul căreia putem aproxima rezultatele dorite. Metoda cea mai des întâlnită în antrenarea acestor rețele este propagarea înapoi.




Figura 12 - Modul de generare al următorului element de conținut; verde reprezintă elementul de input și portocaliu cel de output [19]

¹⁴ Lanțurile Markov reprezintă un proces stohastic ce este caracterizat prin faptul că stările ulterioare ale unui sistem depind de cele anterioare.

¹⁵ Secvență continuă de *N* elemente adeseori formată pe baza unui text.

Astfel o rețea LSTM a fost implementată de către Summerville și Mateas, rețea ce va urma să genereze conținut pentru „*Super Mario Bros*”. După ce modelul a fost antrenat folosind reprezentări vectoriale ale nivelelor, acesta a reușit să genereze nivele noi [19]. În articol harta ce urmează să fie procesată este reprezentată în 3 moduri secvențiale diferite, cu scopul de a găsi reprezentarea cu cele mai bune rezultate. În cele din urmă au reușit să adauge rețelei noi informații precum adâncimea secvenței relativ la geometria nivelului, astfel reușind să antreneze modelul nu doar pe structuri de bază dar și pe progresia nivelului și unde acesta ar trebui să se termine. În *Figura 12* se poate observa structura internă a procesului de generare.

Alt exemplu distinct de generare de conținut în jocuri folosind rețele LSTM este reprezentat de generarea de cărți pentru „*Magic: The Gathering*”¹⁶. Modelul creat de Morgan Milewicz, după ce a fost antrenat pe un set întreg de cărți de joc, a reușit să genereze cărți noi [20].



Figura 13 - Specificarea parțială a unei cărți urmate de output

Cărțile au fost reprezentate

prin câmpuri de text ale costului, tipului, numelui etc. El a menționat că un dezavantaj al folosirii acestei reprezentări o constituie imposibilitatea de a condiționa conținutul câmpurilor ce apar mai târziu în secvența cărții (*Figura 13*).

3.2. Reprezentare sub formă de grilă

Majoritatea nivelelor din jocuri 2D pot fi reprezentate folosind grile cu două dimensiuni. Câteodată această reprezentare nu se potrivește perfect din cauza formelor sau a alinierii unor

¹⁶ Joc de cărți, creat de matematicianul Richard Garfield, ce se joacă în 2 sau mai mulți jucători, jocul reprezentând o bătălie între vrăjitori.

elemente de conținut, dar în același timp putem spune că această reprezentare este cea mai naturală pentru multe tipuri de nivele precum temnițe, hărți strategice chiar și jocuri platformă.




Figura 14 - Nivel din Super Mario Bros generat de lanțuri Markov multidimensionale

A) Numărarea frecvențelor

După ce am analizat lanțurile Markov unidimensionale, pasul următor este folosirea lanțurilor Markov multidimensionale sau **MdMCs** [21]. Diferența între cele două este că în cele unidimensionale

starea este reprezentată printr-o dimensiune liniară singulară în timp ce în MdMCs starea este reprezentată printr-o întreagă vecinătate, oferind dependențe de la mai multe stări în direcții multiple. Astfel, o nouă abordare a generării de nivele a apărut când Snodgrass și Ontañón au folosit în cercetarea lor MdMCs. Primul pas a fost reprezentarea hărții din „*Super Mario Bros*” sub formă de grilă. Pentru fiecare element din grila rezultată, modelul calcula probabilitățile asociate tipului său. De data aceasta modelul lua în considerare întreaga vecinătate și nu doar starea precedentă. Unul dintre rezultatele lor se poate observa în Figura 14 . După noua lor abordare, au utilizat și câmpuri aleatorii Markov sau **MRF**. Modelul creat a reușit să se descurce mult mai bine față de standardul MdMC (în generarea nivelelor de „*Kid Icarus*”) [22] .

B) Propagarea înapoi

Jan ș.a. au arătat cum autoencoderii sunt capabili să fie antrenați să reproducă nivele din originalul „*Super Mario Bros*”. Autoencoderii au fost antrenați pe porțiuni ce aparțineau nivelelor originale, cu scopul de a le transforma într-o reprezentare mult mai generică. De asemenea ei au descoperit că dimensiunea cea mai potrivită a porțiunilor pe care autoencoderii sunt antrenați este de lungime 4 [23]. Autoencoder-ul poate fi folosit mai târziu pentru a diferenția nivelele generate de cele originale și în același timp să repare nivelele ce nu pot fi jucate prin schimbarea caracteristicilor elementelor. Această procedură fiind una dintre cele mai

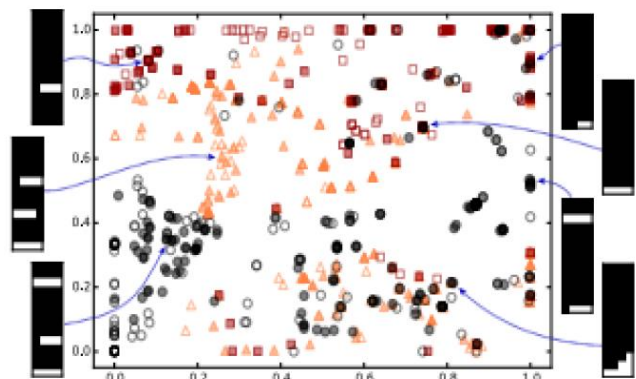


Figura 15- Detectarea nivelului ce conține o anumită porțiune de hartă folosind autoencodere



Figura 16 - A) Original B)Generat C) Reparat

umană. În Figura 16 se observă diferența între cele 3 forme de conținut.

O altă întrebare a rețelelor neuronale abordată de către Lee ș.a. [24] este folosirea rețelelor neuronale convoluționale cu scopul de a prezice locațiile resurselor din cadrul unei hărți de „StarCraft II”¹⁷. De obicei resursele sunt plasate pe hartă în funcție de topologia zonei respective, ele reprezentând un factor esențial în modul în care se desfășoară acțiunea. Folosind acest lucru, ei au transformat harta din joc într-o grilă pe care a introdus-o ca și date de intrare pentru procesul de antrenare al modelului. Un dezavantaj major pentru ei a fost setul de date mic, care de multe ori a dus la *overfitting*-ul¹⁸ rețelei neuronale. Dar prin adăugarea unor pași noi la sfârșitul procesării a reieșit un produs de înaltă calitate permițând dezvoltatorilor să modeleze și să creeze resurse fără a pierde din credibilitatea jucătorilor (Figura 17).




Figura 17 - Aranjarea resurselor pe harta din StarCraft II

C) Factorizarea matricelor

Sunt câteva abordări ce implică folosirea procedurii de **factorizare a matricelor** pentru a găsi caracteristicile unui nivel. În acest fel caracteristicile sunt obținute prin comprimarea datelor în matrice de mici dimensiuni. Shaker și Abou-Zleikha au reușit să creeze folosind nivele generate prin metode ce nu folosesc machine learning, nivele ce sunt mult mai expresive și mai credibile pentru jucător. Ei au comprimat fiecare nivel în mici matrice bazându-se pe tipul de conținut.

¹⁷ Joc militar de strategie produs de *Blizzard Entertainment* în 27 Iulie 2010.

¹⁸ Producerea unei analize ce corespunde prea mult unui set de date particular, producând erori în predicții ulterioare datorită incapacității de a modela noi date.

Fiecare matrice este apoi factorizată și transformată în „*bucăți de matrice*” și coeficienți, ce reprezintă greutatea specifică fiecărei caracteristici sau model [25].

3.3. Reprezentare folosind grafuri

Una dintre cele mai generice metode de a reprezenta datele sunt grafurile, dar generalitatea reprezentării vine cu costul proprietăților structurale (ex. informațiile legate de vecinătatea elementelor fiind oferite implicit prin reprezentarea folosind grile).

i) Maximizarea așteptărilor

Această metodă constă într-un algoritm iterativ ce încearcă să estimeze probabilitatea maximă pentru parametrii unei metode. Această metodă reprezintă o implementare generică pentru orice model ce se bazează pe probabilitatea unui anumit tip de date. Guzdial și Riedl au reușit să folosească clusterizarea ierarhică folosind **K-means** pentru a antrena modelul. Modelul a fost antrenat cu frame-uri din videoclipuri ce surprindeau oameni în timp ce se jucau „*Super Mario Bros*”, model ce va fi folosit mai târziu pentru a genera noi nivele [26]. Ei au procesat fiecare frame al video-ului folosind OpenCV¹⁹. Fiecare frame a fost mai târziu combinat pentru a forma structuri geometrice ale nivelului ce vor fi mai târziu folosite ca și date de input pentru generarea întregului nivel. Ei au folosit o structură de graf ce codifica stilurile formelor și probabilitățile relațiilor dintre acestea. Primul pas a fost clusterizarea porțiunilor din nivel cu scopul de a deriva formele proprii ale acestora, după care au clusterizat formele pentru a obține stilurile acestora, iar ultimul pas a constituit calcularea probabilităților relațiilor dintre acestea pentru a determina cum pot fi combinate între ele cu scopul de a genera nivele noi. În Figura 18 putem observa graful generat pentru câteva porțiuni din nivelurile *Super Mario Bros*.




Figura 18 - Graful unui nivel *Super Mario Bros* din nori

¹⁹ Bibliotecă software ce oferă funcționalități în domeniul computer-vision și machine learning.

3.4. Observații și concluzii

În urma analizei desfășurate putem constata că jocurilor de tip platformă sunt cea mai populară țintă pentru generarea procedurală de conținut folosind machine learning. De asemenea, se poate observa faptul că cele mai importante descoperiri sunt pe jocuri ce „hrănesc” conținutul jucătorului în mod secvențial, făcând ușoară analiza completării nivelului.

Este greu să comparăm nivelele între ele nefiind un standard general ce descrie cât de „corect” este un nivel generat (Posibilitatea de a completa nivelul?; Diversitatea acestuia?), iar abordările de mai sus nu menționează cât timp a fost necesar pentru antrenare sau generarea nivelului. Totuși, ne putem asuma faptul că rețelele neuronale de tip LSTM vor necesita mult mai mult timp de antrenament față de MdMCs. Ambele generează element cu element conținutul, dar abordarea folosind rețele neuronale de tip LSTM necesită mai multă putere computațională pentru a putea fi antrenată. Mai mult de atât, MdMCs pot fi antrenate printr-o singură trecere a nivelelor, în timp ce LSTM va necesita mai mult de o singură epocă de antrenament.

În concluzie, în cadrul acestui capitol am creat o imagine de ansamblu asupra diferitelor metode de generare a conținutului în jocuri procedural folosind machine learning. Am putut observa cum în zilele noastre **PCGML** joacă un rol important, dar totodată marea distanță care mai este de parcurs până să se obțină o generare de conținut mai complex.

4. Aplicație

4.1. Specificarea problemei

Conform observațiilor făcute asupra abordărilor populare din cadrul domeniului de PCGML, în cadrul acestui capitol vom propune o implementare ce va încerca să rezolve câteva dintre cele mai importante probleme identificate.

a) Majoritatea jocurilor redau conținutul secvențial jucătorului

Am dori să tratăm această problemă prin îndepărtarea de la implementări ce au ca și scop crearea de conținut pentru jocuri precum „*Super Mario Bros*”, joc ce este prezent în proporție de 80% în literatură. Jocurile pe care dorim să ne axăm sunt acele jocuri ce oferă jucătorului întregul conținut încă de la început. Având această abordare vom putea analiza ce rată de succes avem în generarea unor altor tipuri de joc decât cele analizate deja. Totodată, nu vom beneficia de aceeași ușurință pentru calculul nivelului de completare a jocului.

b) Diversitate

Una dintre cele mai importate probleme observate în literatură o reprezintă diversitatea. Deși abordări precum rețele LSTM încearcă să rezolve această problemă, ele sunt îngreunate de modul în care anumite jocuri funcționează. Astfel dorim să putem genera conținut ce seamănă foarte puțin cu nivelele de la care am plecat, astfel asigurându-ne ca fiecare nivel va fi interactiv pentru jucător.


Luând în considerare punctele *a)* și *b)* am considerat că cel mai potrivit joc pentru această abordare este ***Lode Runner***. Acesta nu oferă jucătorului conținutul într-un mod secvențial, ci întregul nivel este afișat încă de la început. Un alt avantaj al acestei alegeri este că întreaga arhitectură a nivelului poate fi modificată oricât de mult, astfel dându-ne posibilitatea de a avea un grad de diversitate ridicat.

4.2. Lode Runner

Lode Runner este un joc de tip platformă ce a fost publicat în anul 1983 de către Brøderbund. Față de celelalte jocuri unde focusul era pe acuratețea săriturilor și modul de mișcare, nivelele din *Lode Runner* sunt de tip puzzle .

Aspecte de bază și strategii

Jucătorul este reprezentat printr-o figurină ce trebuie să colecteze toate cuferele de aur și să evite cu orice cost inamicii ce încearcă să-l captureze. După ce a colectat toate cuferele de aur acesta trebuie să ajungă la ultimul etaj al nivelului pentru a putea trece la nivelul următor. Jocul original constă în 150 de nivele ce cresc în dificultatea progresiv astfel oferind o provocare continuă jucătorului. Nivelele oferă diferite structuri cu care jucătorul poate interacționa: scări, cărămizi și bare ce pot fi traversate. De notat este faptul că jucătorul poate săpa gropi de o parte sau de alta a sa. Acest lucru introduce o strategie importantă deoarece pentru a putea săpa o groapă este nevoie de cel puțin 2 spații libere.



Inamici

Gardienii ce încearcă să prindă jucătorul nu au mereu cea mai simplă de prezis traiectorie, alegând drumul cel mai scurt. Ei se mișcă într-o direcție contraintuitivă astfel încât jucătorul trebuie mereu să analizeze și să aleagă drumul cel mai bun. Acest lucru constituie un factor important deoarece dă posibilitatea jucătorului să găsească metode inovative și strategii potrivite pentru a termina respectivul nivel. Jucătorul are voie să stea pe capul inamicilor fără ca acesta să piardă o viață, astfel dând posibilitatea unor noi strategii precum prinderea inamicilor în capcană în gropile săpate ca mai apoi să poți traversa peste capul lor pentru ați atinge obiectivul propus.

Alte reguli

De multe ori este nevoie ca ordinea de traversare a nivelului să fie una corectă deoarece alegerea unei direcții diferite poate duce la blocarea sau prinderea jucătorului de către inamici. Totodată, trebuie să fie atent la numărul de vieți rămase deoarece acestea îi oferă posibilitatea jucătorului de a reîncerca nivelul curent. Jucătorul pornește de la început cu un număr de 5 vieți. Un alt lucru important îl reprezintă timpul, deoarece gropile săpate sunt umplute automat după un anumit timp.

4.3. Dezvoltarea aplicației

Acest capitol va surprinde principalele etape ale dezvoltării unei aplicației. Deși aceste metodologii sunt adesea folosite în crearea software-urilor de sine stătătoare, consider că aplicarea acestor etape duce la o mai ușoară dezvoltare ulterioară a produsului finit.

Analiza

În această fază de dezvoltare vom analiza cerințele sistemului independent de implementare sau proiectare. Aici vom defini problema pe care dorim să o rezolvăm și vom crea o diagramă cu diferitele cazuri de utilizare a aplicației. Tot aici vom dori să analizăm modul în care diferite sisteme comunică între ele și ordinea în care o fac.

Proiectare

În faza de proiectare vom stabili arhitectura sistemului pe baza cerințelor din etapa de analiză. Aici vom configura componentele sistemului precum și comportamentul acestora. Vom analiza totodată și planul de implementare a cerințelor unde vom stabili detalii precum tehnologiile folosite, mediul de dezvoltare, limbajele de programare, structurile de date etc.

Implementare

În cadrul acestei etape vom construi sistemul pe baza cerințelor din etapele anterioare. Aici vom gestiona probleme referitoare la calitatea produsului, biblioteci folosite precum și performanța aplicației.

Testare

Calitatea fiind foarte importantă în cadrul unui produs software, dorim să putem asigura o bună funcționare a sistemului pe o durată lungă de timp. Astfel implementarea și aplicarea testelor pe produsul dorit este necesară, evitând astfel costuri mari pentru modificări ulterioare.

4.3.1. Analiza cerințelor




Figura 19 - Diagrama cazurilor de utilizare

Primul pas în analiza cerințelor îl constituie întocmirea diagramei cazurilor de utilizare. După cum se poate observa, Figura 19 surprinde principalele cazuri în care actorii interacționează cu aplicația.

Antrenarea modelului constituie unul dintre cele mai importante cazuri de utilizare. Dorim ca aplicația să poată crea și antrena un model ce va fi mai târziu folosit în generarea nivelelor pentru joc. De asemenea se poate observa ca se dorește ca după ce modelul a fost antrenat, să se poată analiza rezultatele cu privire la antrenarea sa.

Un alt caz important de utilizare îl constituie posibilitatea **testării modelului** antrenat de către dezvoltator. Astfel se poate observa cât de bine se descurcă modelul când întâmpină alte date decât cele pe care a fost antrenat. Dorim de asemenea să putem vizualiza rezultatele testării modelului.

Ultimul dar nu cel din urmă caz de utilizare este **jucarea jocului**. Jucătorul trebuie să poată interacționa cu conținutul pe care noi îl generăm.

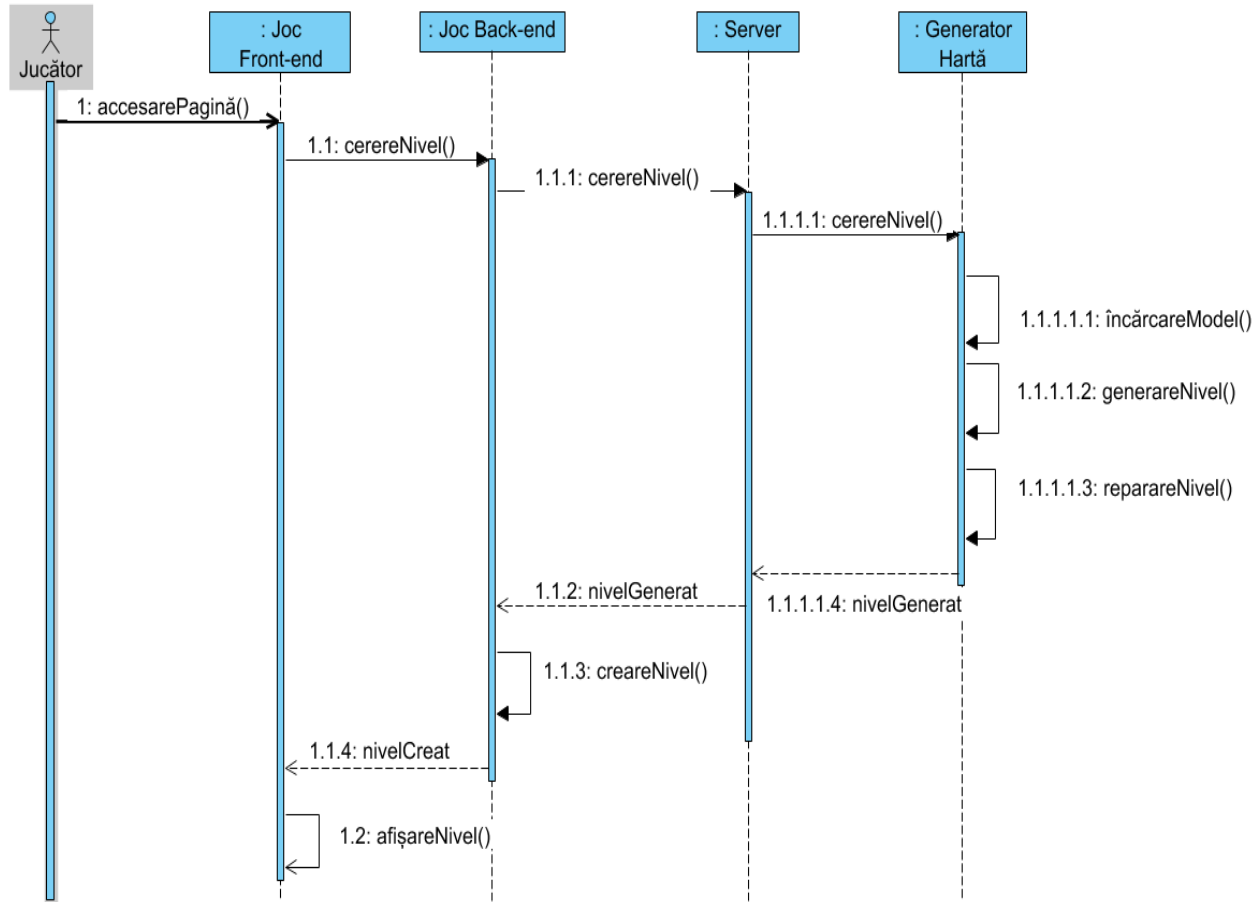


Figura 20 - Diagramă de secvență pentru deschiderea jocului

Pentru a surprinde cazurile de utilizare în amănunt le vom analiza folosind diagrame de secvență specifice. Cu ajutorul acestora vom putea observa modul în care componentele comunică între ele în cadrul aplicației și ordinea în care fiecare sistem trimite și primește mesaje. După cum se poate observa Figura 20 reprezintă diagrama de secvență pentru momentul în care jucătorul pornește jocul. Deja putem observa că vom avea nevoie de un server cu care trebuie să comunicăm

pentru a primi un nivel generat. Este necesară implementarea unui server deoarece vrem ca diverși jucători să poată comunica cu serviciul implementat pentru generarea nivelului. O altă observație pe care o putem face este aceea că generarea nivelului se face prin încărcarea modelului antrenat și punerea lui în aplicare, dar și nevoia strictă de repararea a nivelului generat.

Ca toate abordările de până acum, vom avea nevoie de o metodă prin care să reparăm nivelul generat, astfel asigurând un nivel ce poate fi jucat. Această reparare se va face în urma procesului de reparare, și va consta în aplicarea unor constrângeri asupra nivelului **generat**.

Un alt lucru ce se poate observa din Figura 20 este că avem nevoie ca jocul nostru să poată citi rezultatul primit de la server, pentru a-l putea construi și afișa jucătorului.




Figura 21 - Diagramă de secvență pentru antrenarea modelului

Figura 21 surprinde o altă diagramă de secvență din cadrul aplicației. Aici vom analiza modul în care componentele aplicației comunică între ele în momentul antrenării unui nivel. Se observă prima etapă din antrenare o constituie crearea modelului ce urmează a fi antrenat. După antrenament dorim să se poată salva modelul pentru a putea fi utilizat mai târziu. Această etapă este esențială deoarece pentru generarea de conținut ulterioară vom avea nevoie de modelul pe care l-am antrenat. Totodată, se dorește salvarea modelului la momentul în care acesta este mai bun prin comparație cu cel precedent. Urmând acest proces vom putea crea un model din ce în ce mai performant.

O altă observație importantă referitoare la Figura 21 o reprezintă posibilitatea de a analiza rezultatele în urma sesiunii de antrenament. Astfel putem observa modul în care modelul evoluează și momentele în care acesta întâmpinăm dificultăți referitor la antrenament. Rezultatele pot fi sub formă de text sau grafice.

4.3.2. Proiectarea aplicației

În urma analizei efectuate în cadrul etapei anterioare, putem realiza arhitectura sistemului pe care dorim să-l implementăm precum și alegerea tehnologiilor și a limbajelor folosite. Se observă totodată că vom avea nevoie să implementăm un sistem ce face posibilă comunicarea dintre *Lode Runner* și generatorul de nivele. Acest sistem trebuie să fie rapid ca și durată de răspuns deoarece așteptarea prea îndelungată a jucătorului pentru generarea hărții reprezintă un dezavantaj major.

Scopul acestei aplicații este să analizeze crearea de conținut în jocuri folosind machine learning și nu implementarea acestora. Astfel, am ales să folosim un joc deja implementat ce încearcă să imite cu până la cele mai mici detalii jocul original. Implementat în anul 2017 de către Simon Hung, *LodeRunner_TotalRecall* reprezintă o copie fidelă a faimosului joc *Lode Runner* [27]. Jocul este implementat folosind **CreateJS**²⁰ având la bază **HTML5**. Dacă se dorește experimentarea cu această implementare a jocului, acesta poate fi accesat și jucat la următoarea adresă: <http://LodeRunnerWebGame.com>.

²⁰ Librărie de funcționalități folosită pentru crearea de conținut interactiv.

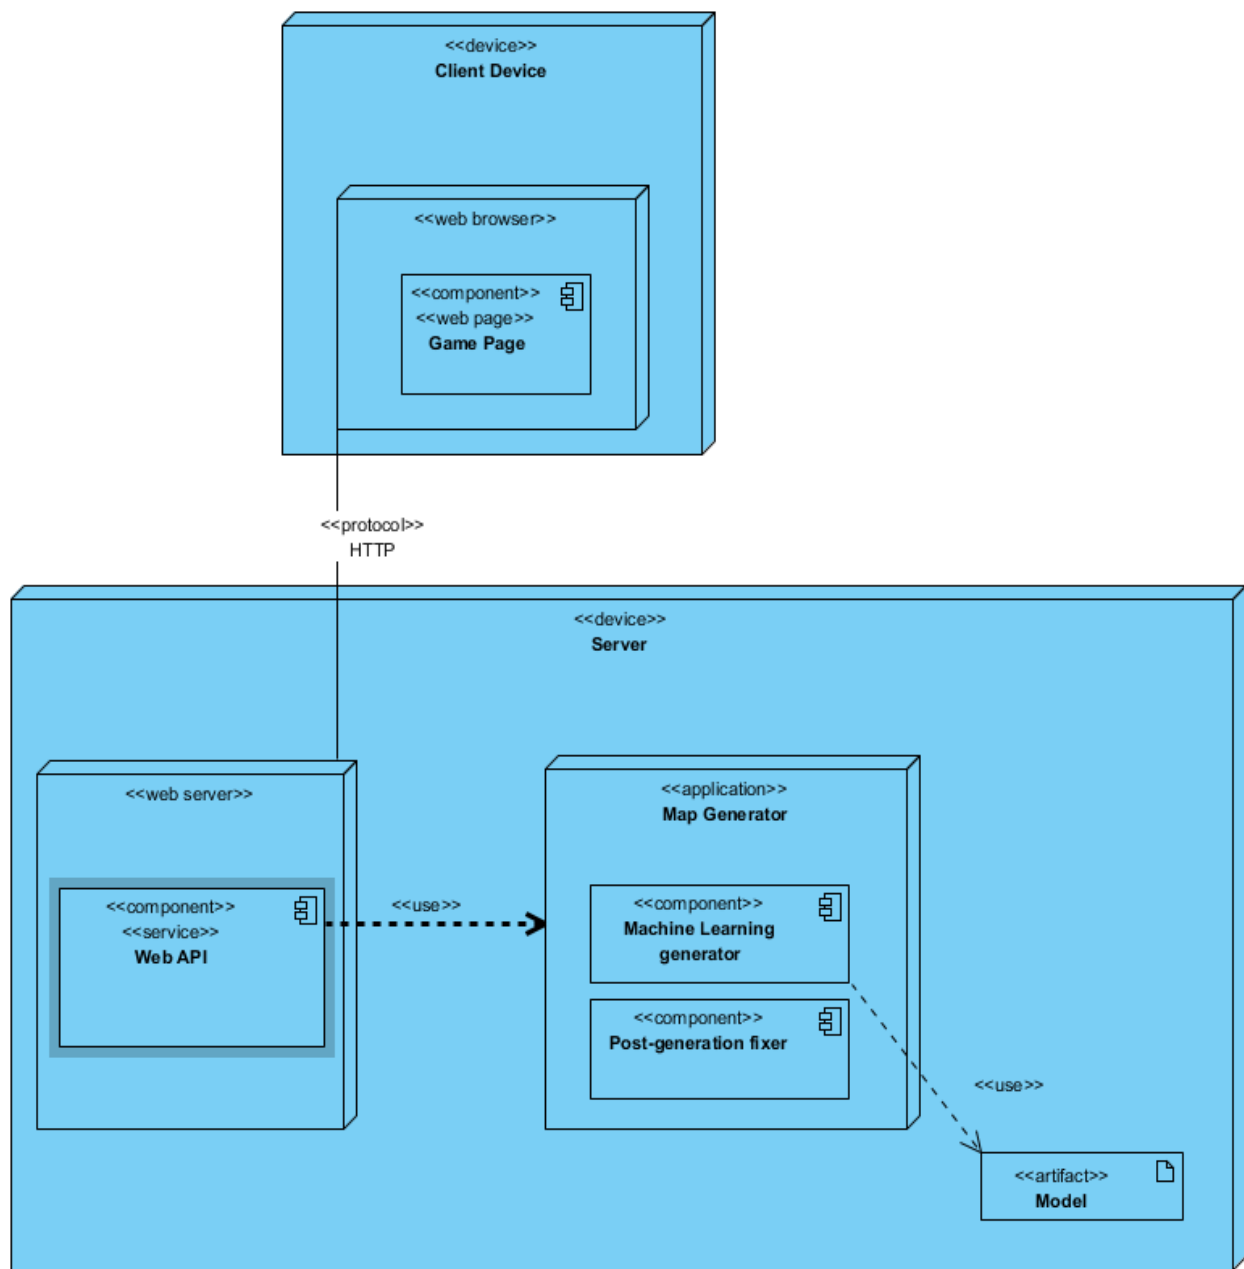


Figura 22 - Diagramă de componente a aplicației

În cadrul Figura 22 am încercat să surprindem principalele componente ale aplicației și modul în care acestea vor fi structurate. Prima componentă reprezintă dispozitivul de pe care jucătorul se joacă *Lode Runner*. Jocul va fi accesat dintr-o pagină web ce va comunica cu serverul ce are ca și scop generarea nivelului. Comunicare se va face prin **HTTP** (Hypertext Transfer Protocol) având astfel posibilitatea ca mai mulți clienți să comunice cu serverul nostru [28].

Al doilea nod îl reprezintă serverul ce urmează să fie implementat. Acesta va conține un Web API ce va face posibilă primirea de request-uri de la client și trimiterea răspunsului înapoi. După ce a primit cererea Web API-ul va folosi o componentă de generare a nivelului. Această componentă va consta din 2 părți: o parte ce generează nivelul folosind un model deja antrenat și testat, în timp ce a doua parte are ca scop repararea nivelului generat, pentru a ne asigura că acesta respectă regulile jocului și ca nu este corupt în vreun fel.

După ce nivelul a fost generat cu succes, acesta va fi trimis către dispozitivul clientului folosind același protocol de comunicare. Avem nevoie ca comunicarea dintre dispozitivul

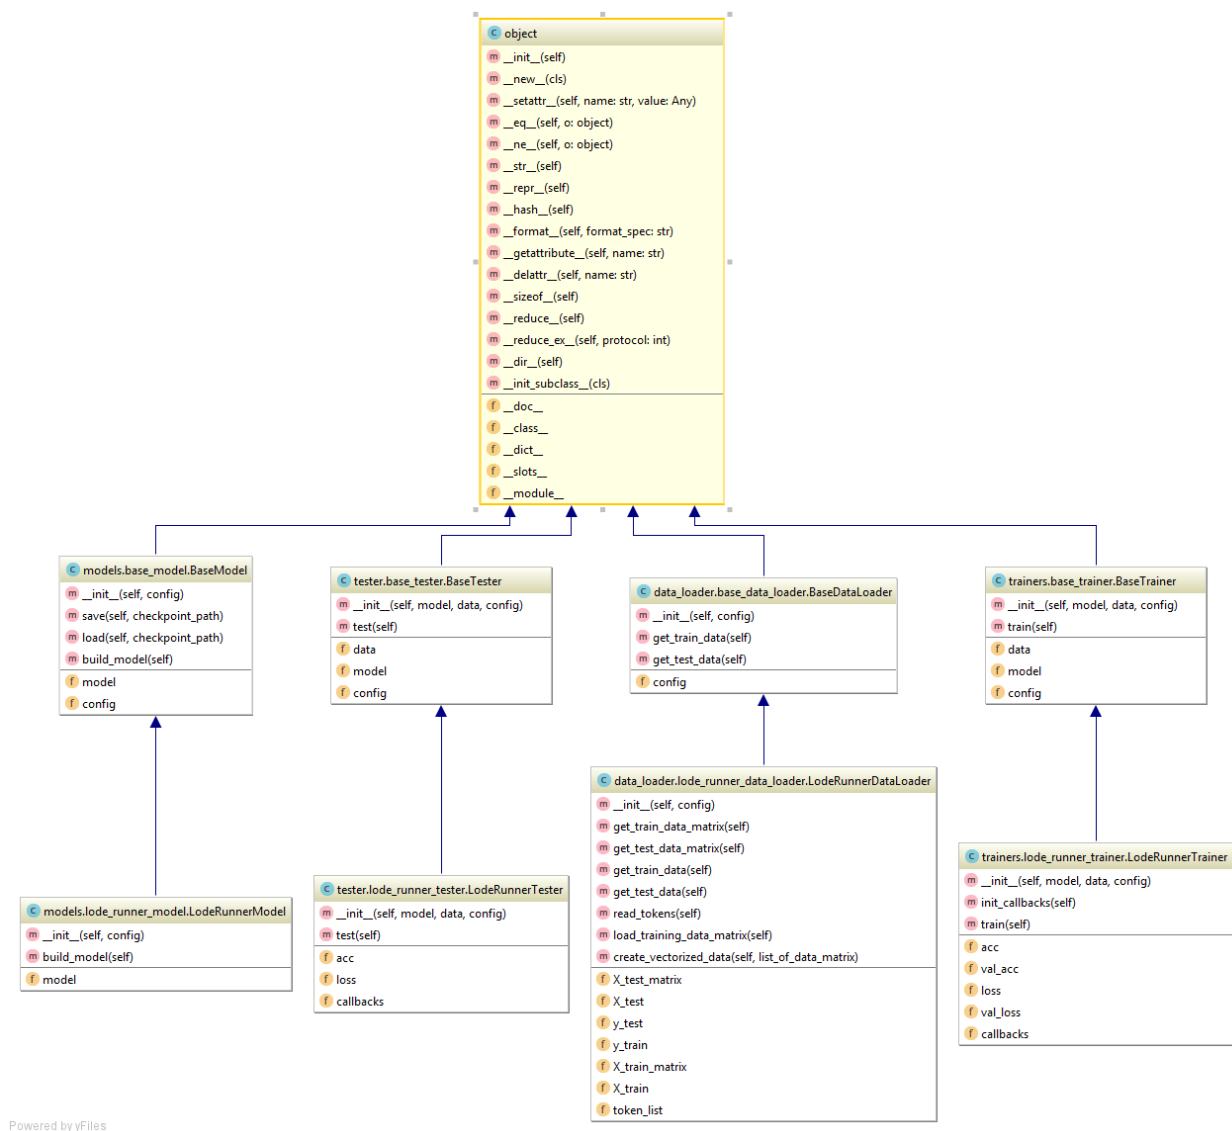


Figura 23 - Diagrama de clase

clientului și serverul nostru să fie de tip asincronă deoarece nu dorim ca jocul să se blocheze așteptând după generarea nivelului.

Pentru antrenarea modelului vom folosi o aplicație conform diagramei de clase din Figura 23. După cum se poate observa aceasta va fi compusă din 4 module. Fiecare obiect va moșteni o clasă abstractă pentru a ușura în viitor extinderea aplicației. În cele ce urmează voi descrie scopul fiecărei clase în cadrul aplicației. **DataLoader**, se va ocupa cu modelarea datelor de intrare, acesta va executa o preprocesare a datelor cu scopul de a le pregăti pentru etapa de antrenare a modelului. **Trainer**, acesta se va ocupa cu antrenarea modelului folosind datele procesate de către **DataLoader**. Tot acest modul se va ocupa și cu salvarea datelor obținute în urma antrenamentului. **Tester**, se va ocupa cu testarea modelului după antrenare pentru a ne asigura că modelul evaluează corect date pe care le întâlnește pentru prima dată. **Model**, în cadrul acestei clase vom defini arhitectura și modul în care vom salva sau încărca modelul obținut.

4.3.3. Tehnologii folosite

ASP.NET

Pentru crearea serviciului vom folosi *ASP.NET*. Acesta este o tehnologie Microsoft utilizată pentru crearea de servicii și aplicații web. Arhitectura serviciului va fi una de tip RESTful (Representational State Transfer), deoarece ne oferă flexibilitate în ceea ce privește dezvoltarea serviciului. Cu ajutorul acestuia și cu framework-ul *ASP.NET Web API* vom construi serviciul ce se va ocupa cu transmiterea nivelurilor între client și serverul construit. Pentru implementarea și dezvoltarea aplicațiilor de tip ASP.NET vom avea nevoie de un mediu specific.



Visual Studio

Acest mediu de dezvoltare integrat (IDE) oferă un pachet întreg de instrumente ce ne permite dezvoltarea aplicațiilor de tip ASP.NET. Totodată, **Visual Studio** oferă accesul la tehnologii esențiale ce ușurează procesul de dezvoltare a aplicațiilor web, beneficiind astfel de caracteristicile **framework-ului .NET**.



Visual Paradigm

Visual Paradigm reprezintă o unealtă **UML** (Unified Modeling Language) **CASE** **Visual Paradigm** (Computer aided-software engineering) ce oferă un mediu unde putem modela și analiza aplicația ce este sau urmează să fie implementată. Am folosit această unealtă pentru generarea diagramelor și asigurarea unui model complet și corect al aplicației.

Postman



Cum testarea reprezintă o etapă esențială din procesul dezvoltării, vom avea nevoie de o metodă cu ajutorul căreia să putem **testa API-ul** creat. Astfel, deoarece testarea în cadrul interfeței cu utilizatorul presupune un nivel ridicat de complexitate, trebuie să putem testa serviciul într-un mod decuplat față de aceasta, în izolare. Postman este construit dintr-un set de unelte ce permite dezvoltatorilor de servicii web să-și testeze aplicațiile. Acesta este folosit pentru a determina dacă serviciile expuse de către noi returnează răspunsul corect, în formatul dorit. În felul acesta putem asigura funcționarea corectă a aplicației.

TensorFlow

TensorFlow reprezintă o librărie software ce pune la dispoziția programatorului o multitudine de funcționalități deja implementate din domeniul matematicii. El este adeseori folosit în cadrul domeniului de **machine learning**, facilitând implementarea pentru tot felul de aplicații precum rețelele neuronale. Oferă programatorilor și inginerilor flexibilitate precum și o metodă rapidă de a pune în aplicare diferite abordări din cadrul acestui domeniu. Noi vom folosi TensorFlow ca și back-end al API-ului ce se va ocupa cu antrenamentul modelului.



Keras

Keras reprezintă o librărie open source scrisă în Python, ce este capabilă să ruleze având ca și parte de back-end TensorFlow, Theano sau Microsoft



Cognitive Toolkit. Ea fost dezvoltată pentru a oferi dezvoltatorilor o interfață ce este capabilă să implementeze diverse abordări din domeniul **machine learning**. Totodată, Keras oferă aplicațiilor extensibilitate și modularitate. Modularitatea librăriei este pusă în evidență prin posibilitatea configurării modulelor ce pot fi combinate. Componente precum: straturi neuronale, funcții de cost, optimizatori și funcții de activare pot fi combinate pentru a crea noi modele. Un alt motiv important pentru care am considerat Keras este posibilitatea de a ne antrena rețeaua pe **placa video**, astfel micșorând considerabil timpii de antrenare a modelului.

PyCharm



Deși deja folosim Visual Studio ca și mediu de dezvoltare al Web API-ului, avem nevoie de alt mediu pentru care să ne faciliteze utilizare librăriei Keras și a limbajului de programare Python. PyCharm dezvoltat de către JetBrains ne oferă o gamă largă de unelte pentru dezvoltarea și mentenanța aplicațiilor scrise în Python. Câteva avantaje de care dispunem prin alegerea acestui mediu de dezvoltare sunt: analiza codului, interfață accesibilă de debugging și testare unitară integrată.

Git

Git reprezintă un sistem de control ce se ocupă cu urmărirea schimbărilor din cadrul unei aplicații. Pentru a deține controlul complet asupra **versiunilor** aplicației vom folosi Git împreună cu SourceTree. Cel



din urmă ne va oferi o interfață ușoară de înțeles ce va facilita procesul de mentenanță.

Limbaje de programare: Python și C#

4.3.3. Implementare

Configurarea jocului

Primul pas în implementarea aplicației îl constituie asigurarea bunei funcționări a jocului *Lode Runner*. După ce am clonat *LodeRunner_TotalRecall* local vom încerca să-l pornim. Deoarece jocul a fost implementat folosind javascript, vom folosi Visual Studio pentru a îl putea porni. În

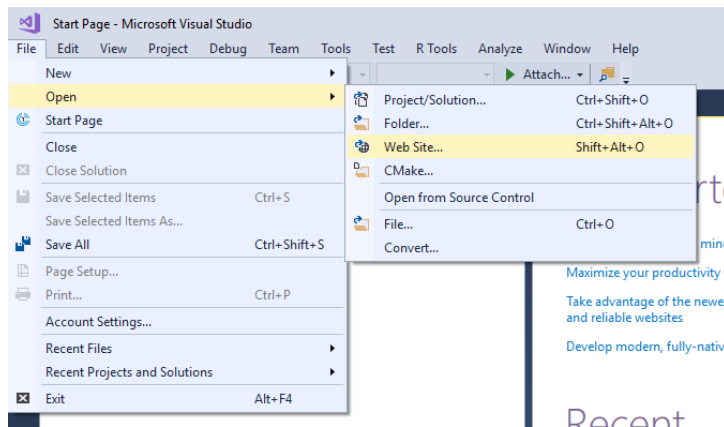


Figura 24 - Pornire joc Lode Runner folosind Visual Studio

Figura 24 putem observa ca Visual Studio ne oferă opțiunea de a porni un proiect ca și un Web Site, exact ceea ce avem nevoie pentru a ne porni jocul. După ce am deschis proiectul putem observa structura jocului. După cum se poate observa putem regăsi diferite fișiere javascript ce se ocupă cu diferite funcționalități ale jocului (Figura 25).

Pentru a putea inițializa jocul trebuie să navigăm la fișierul *lodeRunner.html*, iar după ce apăsăm click dreapta pe acesta alegem opțiunea *View in Browser*. Datorită versiunii optimizate de ISS pentru dezvoltatori, ISS Express, ce este integrată în Visual Studio avem posibilitatea de a ne găzdui propria pagină web. Procesul pornește automat, imediat după ce am selectat opțiunea. După acest pas ISS Express alege un port unde poate găzdui aplicația pe *localhost*. După cum se poate observa în Figura 26 în cazul meu ISS Express mi-a găzduit aplicația la adresa <http://localhost:4245/lodeRunner.html>. După ce am testat jocul și am decis că este complet funcțional am trecut la următoarea etapă a implementării.

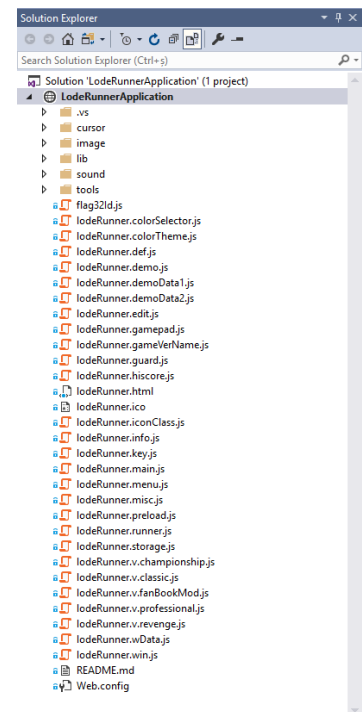


Figura 25 - Structura internă a jocului

Reprezentarea unui nivel

Pentru a putea genera procedural un nivel de *Lode Runner* avem nevoie să identificăm o reprezentare ce poate fi ușor modelată și pe baza căreia să ne antrenăm rețeaua neuronală. Astfel fiecărui element din joc îi va corespunde un caracter în format text.



Figura 26 - Ecranul de start al jocului Lode Runner

Reprezentare grafică	Tipul elementului	Reprezentare text
	Cărămidă normală	#
	Cărămidă tare	@
	Scară de urcat	H
	Bară de cățarat	-
	Cărămidă falsă	X
	Scară invizibilă	S
	Cufăr de aur	\$
	Inamic	0
	Jucător	&
	Spațiu gol	

Conform Tabel 1 toate elementele jocului sunt reprezentate printr-un caracter text. Spațiul gol din nivel nu va fi reprezentat în niciun fel, astfel evitând complicații ce nu sunt necesare. După cum se observă în Tabel 1 scara de urcat și scara invizibilă arată la fel dar sunt reprezentate diferit. Asta deoarece ele au funcții diferite pe parcursul jocului. Scara de urcat poate fi folosită pe toată durata nivelului în timp ce scara invizibilă nu este accesibilă decât după ce toate cuferele de aur fost colectate de către jucător. O altă diferență importantă o constituie cea dintre cărămida normală și cea falsă, cărămida normală poate fi folosită pe tot parcursul nivelului, dar jucătorul cade prin cărămida falsă.

Tabel 1 - Reprezentare nivel

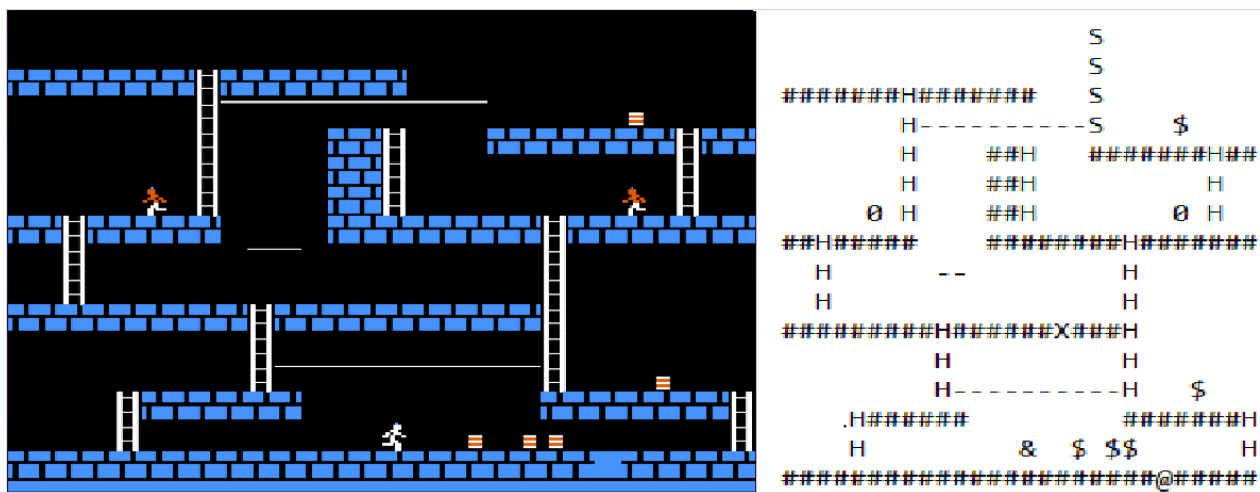


Figura 27 - Nivel Lode Runner și reprezentarea sa

În Figura 27 putem observa compararea dintre un nivel *Lode Runner* și reprezentarea sa. Datorită acestei reprezentări spațiul ocupat de către fiecare nivel este cu mult mai mic. După ce am stabilit modul în care vom reprezenta nivelul în cadrul aplicației putem trece la următoarea etapă.

Comunicarea între joc și server

Implementarea comunicării între joc și server presupune implementarea Web API-ului ce va gestiona transferul de date dintre cele două. Pentru crearea și utilizarea serviciului vom crea un proiect în Visual Studio ce împreună cu jocul vor fi configurate după cum urmează:

- Ne vom asigura că serviciul definește o rută de tip HTTP la adresa: *localhost:port/api/controller*, unde *controller* semnifică numele controlerului implementat.
- Vom implementa un controler cu numele *MapsController()* ce se va ocupa cu tot ce ține de transmiterea nivelelor între jucător și joc.
- Controlerul va implementa o metodă de tip GET ce va răspunde la request-urile din partea jocului. Această metodă se va ocupa și cu apelarea unui scrip python ce va genera și returna un nivel *Lode Runner* (Figura 28).
- Vom verifica dacă serviciul poate fi apelat folosind Postman, chiar dacă inițial nu avem ce script rula, vom returna un șir de caractere de test (Figura 29).
- Vom implementa un request la Web API folosind AJAX în cadrul jocului.

```

5 namespace LodeRunnerMapsAPI.Controllers
6 {
7     public class MapsController : ApiController
8     {
9         [HttpGet]
10        public IHttpActionResult Level()
11        {
12            var result = Run_cmd("D:/LastYear/Licenta/LodeRunnerMachineLearning/generate/main.py", "");
13            return Ok(result);
14        }
15        public string Run_cmd(string cmd, string args)
16        {
17            ProcessStartInfo start = new ProcessStartInfo
18            {
19                FileName = "C:/Users/silvi/AppData/Local/conda/conda/envs/LodeRunner/python.exe",
20                Arguments = string.Format("{0} {1}", cmd, args),
21                UseShellExecute = false,
22                RedirectStandardOutput = true
23            };
24            using (Process process = Process.Start(start))
25            {
26                using (StreamReader reader = process.StandardOutput)
27                {
28                    string result = reader.ReadToEnd();
29                    return "Test";
30                }
31            }
32        }
33    }
34 }

```

Figura 28 - Apelarea scriptului python din C#

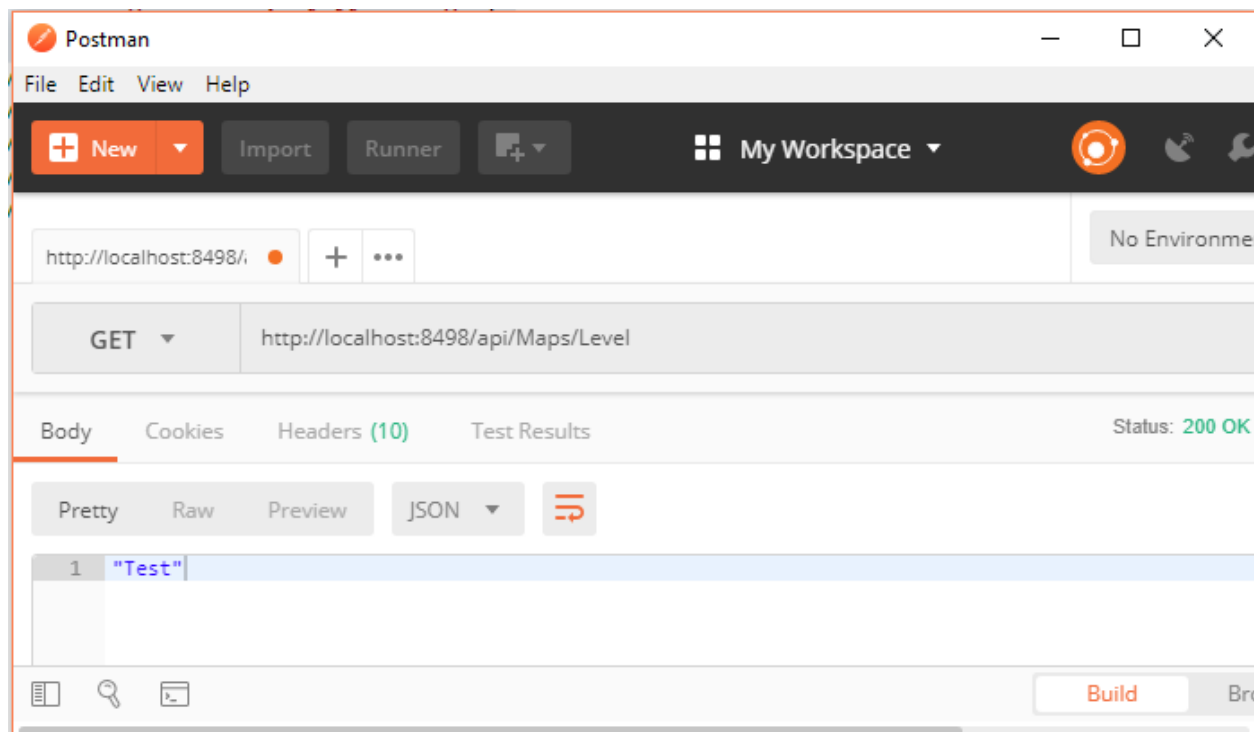


Figura 29 - Testare Web API

Implementarea modelului

Prima etapă de implementare a modelului o constituie alegerea unei arhitecturi potrivite pentru rețeaua neuronală recurentă. Conform analizei făcute la punctele anterioare putem afirma

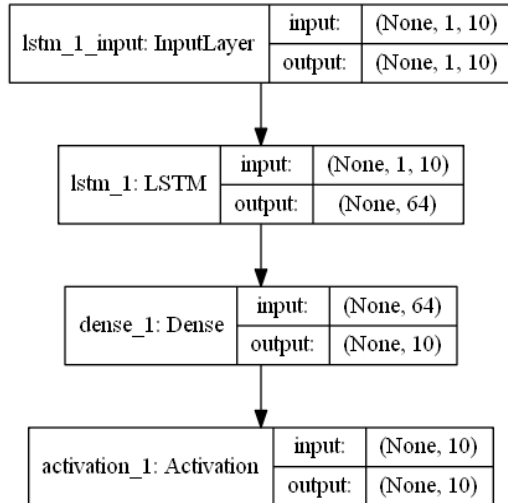


Figura 30 - Arhitectura rețelei neuronale

ca o alegere potrivită pentru tipul rețelei recurente o reprezintă LSTM. În *Figura 30* se poate observa arhitectura aleasă pentru rețeaua ce urmează să fie antrenată. După cum se poate observa primul strat îl reprezintă **InputLayer**, acesta se va ocupa cu transmitia datelor către rețeaua LSTM. Al doilea strat, **LSTM** reprezintă principala funcționalitate a rețelei. Acest strat își va modifica greutatea în funcție de datele de antrenament pentru a putea genera cu succes conținutul pentru nivelul din joc. Al treilea strat, **Dense** reprezintă stratul de output al rețelei, acesta va colecta rezultatele în funcție de predicția făcută. Pentru final avem nevoie

de un strat de **Activare** pentru a putea pune rezultatul în forma dorită. Am ales ca stratul să aibă dimensiunea de 10 deoarece vom avea vectori de către 10 elemente din pricina numărului de elemente prezente în joc.

Conform jocului original am avut la dispoziție un set de date de 150 de nivele pe care le-am separat în fișiere text eliminând toate caracterele străine, astfel am rămas cu fișiere de forma *Figura 31*. Ordinea de citire a fișierului va fi una șerpuită de sus în jos, de la stânga la dreapta deoarece direcția principală de parcurgere a nivelului este pe verticală. O altă metoda de parcurgere ar putea fi pe coloane, dar am considerat că datorită șerpuirii vom oferi mai multe informații rețelei despre cum să

```

$ #####S#####
H#- - - - $S# #
H#$# #### S#H###H###H#
H#$# # # $ S#H###H###H#
H#$# $$$#####S#H #H 0$H#
H#$# #####S###H#H###H#
H#$# $ 0 S #H#H###H#
H#$#####H####$ S $H#H H#
H#$# H #####H#####H#
H#$H###$##H $ #H $ #H#
H#$H# $ #####H#####H#
H#$H# H##H0$ #H $ #H#
H#$#####H#####H#H#
H#$#$ # $ # $ H$ # $ H##
H#X#H#H#H#H#H#H#H#H#H#H#
H $ H#H$H#H$H#& $ H $ H#
  
```

Figura 31 - Reprezentare nivel Lode Runner




Figura 32 - Modul de citire și de generare a nivelelor Lode Runner

genereze nivelul. În Figura 32 se poate observa concret modul în care aplicația va parcurge nivelele.

Pentru pregătirea datelor, vom citi fișierul element cu element în ordinea specificată, fără ultimul element. Fiecare element va fi transformat într-un vector de 10 numere. Fiecare tip de element va avea o poziție în vector unde punem 1

iar restul 0. De exemplu pentru scară vom avea $[0,0,1,0,0,0,0,0,0]$. Toți acești vectori îi vom adăuga într-o listă ce va reprezenta datele de intrare. Pentru ca rețeaua neuronală să poată fi antrenată vom avea nevoie de o listă de vectori ce semnifică răspunsul pe care ne așteptăm să-l obținem. Pentru această listă vom citi din nou nivelul, dar de data asta sărim peste primul element. Acest vector semnificând următorul element pentru elementul curent.

După ce am creat cele două liste, le vom transmite mai departe către procesul de antrenare. De menționat este că pentru această etapă vom folosi doar 66% din nivelele originale. Aici vom urmări pentru fiecare epocă rezultatul obținut și dacă acuratețea modelului a crescut (Figura 33). Dacă modelul este mai bun decât cel anterior îl vom salva pentru al putea folosi ulterior la generarea nivelului.

Ultima etapă o reprezintă etapa de testare a modelului. Aici vom folosi restul de 33% de nivele să verificăm dacă modelul răspunde corect la noile date sau nu. Vom folosi TensorBoard pentru a genera o reprezentare grafică a procesului de antrenare. Aici vom putea urmări evoluția acurateței pe parcursul antrenării.

```

12720/33525 [=====>.....] - ETA: 10s - loss: 1.3896 - acc: 0.5212
12880/33525 [=====>.....] - ETA: 10s - loss: 1.3878 - acc: 0.5213
13072/33525 [=====>.....] - ETA: 9s - loss: 1.3854 - acc: 0.5220
13232/33525 [=====>.....] - ETA: 9s - loss: 1.3842 - acc: 0.5229
13344/33525 [=====>.....] - ETA: 9s - loss: 1.3835 - acc: 0.5220
13488/33525 [=====>.....] - ETA: 9s - loss: 1.3828 - acc: 0.5222
13696/33525 [=====>.....] - ETA: 9s - loss: 1.3826 - acc: 0.5221
13792/33525 [=====>.....] - ETA: 9s - loss: 1.3831 - acc: 0.5223
13872/33525 [=====>.....] - ETA: 9s - loss: 1.3823 - acc: 0.5226
13904/33525 [=====>.....] - ETA: 9s - loss: 1.3815 - acc: 0.5228
14016/33525 [=====>.....] - ETA: 9s - loss: 1.3797 - acc: 0.5232
14128/33525 [=====>.....] - ETA: 9s - loss: 1.3784 - acc: 0.5236
14192/33525 [=====>.....] - ETA: 9s - loss: 1.3778 - acc: 0.5238
14336/33525 [=====>.....] - ETA: 9s - loss: 1.3766 - acc: 0.5239
14512/33525 [=====>.....] - ETA: 9s - loss: 1.3738 - acc: 0.5245
14640/33525 [=====>.....] - ETA: 9s - loss: 1.3725 - acc: 0.5248
14784/33525 [=====>.....] - ETA: 9s - loss: 1.3713 - acc: 0.5250
14960/33525 [=====>.....] - ETA: 9s - loss: 1.3688 - acc: 0.5256
15152/33525 [=====>.....] - ETA: 8s - loss: 1.3659 - acc: 0.5260

```

Figura 33 - Analiza fiecărui batch de date

Implementarea generatorului

Pentru generarea nivelului vom folosi nivelul implementat la etapa anterioară. Acesta va fi folosit pentru a returna un vector de probabilități pentru elementul curent. Folosind acest vector vom genera următorul element ș.a.m.d. Vom avea nevoie în total de un număr de 448 de elemente, deoarece un nivel este format din 28 de coloane și 16 linii.

În cadrul scriptului ce urmează să genereze noul nivel, vom avea și câteva etape ce vor avea ca și scop repararea nivelului generat. Deși rețeaua va putea prezice structurile scărilor și numărul acestora, avem nevoie să ne asigurăm că nivelul poate fi terminat și este valid. Reparările constau în: eliminarea sau adăugarea de inamici/cufere cu aur, poziționarea corectă a cărămizilor în jurul scărilor, eliminarea zonelor unde jucătorul ar putea rămâne blocat ș.a.

Scriptul va fi apelat din cadrul Web API-ului folosind executabilul python ce a fost configurat conform environmentului de proiectare a rețelei neuronale. După ce nivelul a fost generat, acesta va fi trimis către joc sub forma unui text de 448 de caractere. Aceste caractere sunt mai apoi interpretate de către joc și transformate în elemente din cadrul jocului *Lode Runner*. În *Figura 34* se poate observa modul în care arată un nivel generat de către scriptul implementat.

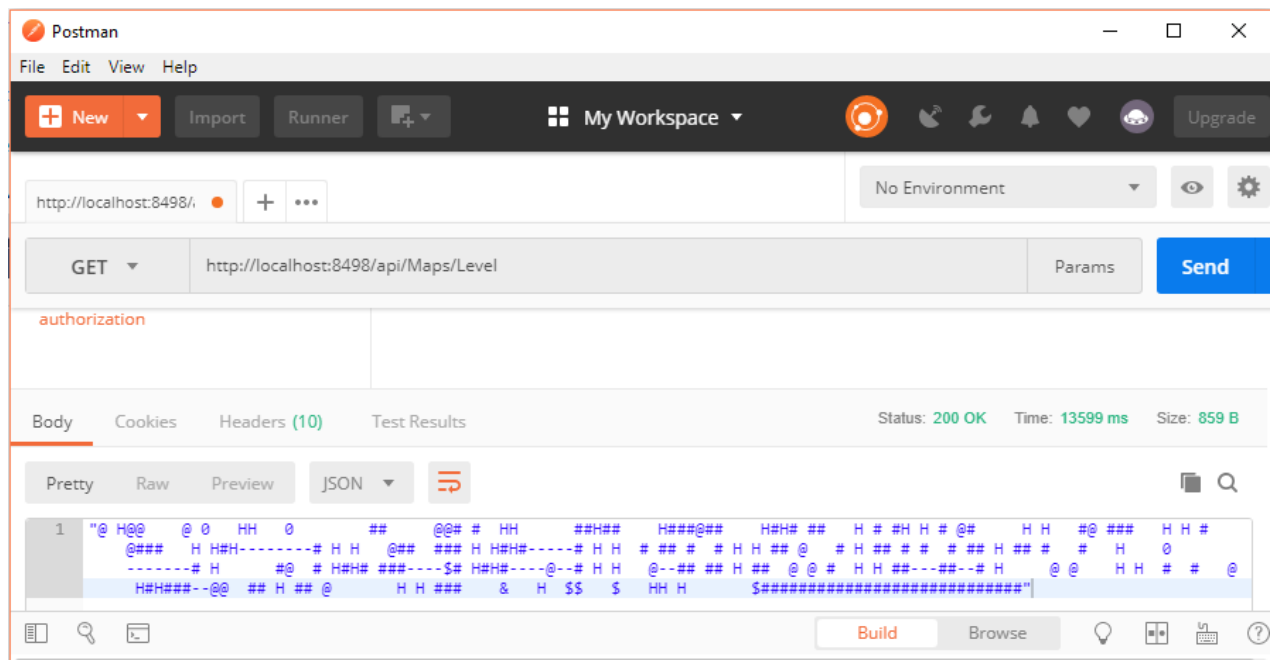


Figura 34 - Nivel generat folosind rețeaua neuronală

4.3.4. Testare

Fiind una dintre cele mai importante etape ale programării, vom implementa teste pentru toate componentele acestei aplicații: serviciul Web API, antrenarea modelului și generarea nivelului.

Testare Web API

▲	✓	WebApiTesting (2)	35 sec
▲	✓	WebApiTesting (2)	35 sec
▲	✓	APITest (2)	35 sec
	✓	Level_Should_Return_Complete_Map	12 sec
	✓	Run_Cmd_Should_Return_Complete_Map	23 sec

Pentru testarea Web API-ului vom urmări două scenarii:

- Endpoint – verificăm dacă serviciul comunică cu succes fără erori (returnează 200 OK).
- Script - verificăm dacă mesajul transmis de către Web API este complet (conține 448 de caractere).

Testare proces antrenare

Aici vom verifica dacă datele sunt transformate corect în vectorii necesari. Vom verifica dacă dimensiunile vectorilor sunt corecte și dacă au fost transformați conform convențiilor anterioare.

Testare generare

Pentru testarea generării nivelului vom verifica dacă datele rămân corecte în timpul procesului de testare și dacă maparea de la vector la caractere text și invers se face corect.

5. Rezultate obținute

Folosind modelul antrenat am reușit să generăm un nivel în formă text după o sesiune de antrenare de 50 de epoci. Pentru învățare am folosit un learning rate de 0.001, iar validare în timpul antrenării a fost în proporție de 25%. După cum se poate observa funcția de loss (Figura 35) se




Figura 35 - Evaluarea funcției de loss

poziționează în jurul valorii de 1.219. Din punctul meu de vedere se datorează faptului că nivelele sunt foarte diversificate între ele și foarte puține predicții pot fi făcute cu succes. Tot din acest motiv putem observa în Figura 36 faptul că acuratețea modelului de la un anumit timp rămâne constant în jurul valorii de 56%.

Deși conform graficelor anterioare pare că modelul nu poate învăța complet structura nivelului, folosirea rețelei LSTM a fost de ajuns pentru a putea prezice structuri cum ar fi scări sau cărămizi. Datorită acestui lucru nivelele generate par a avea o oarecare asemănare cu nivelele din jocul original, nefiind complet aleatorii. După cum se poate observa în Figura 36 nivelul este compus din diferite forme ce seamănă cu nivelele originale. Se mai poate observa și faptul că scările sunt continue fără a apărea întreruperi în cadrul lor. O altă observație care se poate face este




Figura 36 - Evaluarea acurateței modelului

faptul că unele cuferे cu aur nu pot fi accesate datorită structurii nivelului. Tot datorită structurii nivelului cei 2 inamici din partea dreaptă nu pot urmări jucătorul încercând să-l prindă.

Din observațiile făcute mai sus reiese nevoie de a avea implementat un sistem ce este capabil să repare modelul generat de către rețea. Dorim ca acesta să modifice cât mai puțin nivelul generat, mărind astfel probabilitatea ca nivelul creat să poată fi terminat.

După ce am aplicat un set de reguli cu scopul de a repara nivelul (Figura 38) am observat că nivelul este deja mult mai accesibil pentru jucător, dar tot mai sunt câteva probleme în cadrul acestuia precum posibilitatea de a ajunge la ultimul etaj cu scopul de a termina nivelul sau numărul prea mare de cuferе cu aur. În acest scop am mai compus câteva reguli pentru a elimina aceste probleme. Astfel, după aplicarea reparării am reușit să creez procedural primul nivel ce poate fi jucat și terminat de către jucător. Singura problemă a nivelului fiind generarea prea apropiată a cuferelor de aur, dar acest nivel

după evaluare poate fi considerat un nivel de dificultate mică pentru jucătorii începători (Figura 39). Ca și timp de executare și generarea a nivelului, ne poziționăm la 22-25 de secunde. Din acest motiv am decis să avem la începutul jocului un nivel salvat în memorie pentru a avea un timp de buffer ca serverul să reușească să genereze nivelul și să-l trimită către joc.




Figura 37 - Primul nivel generat cu succes




Figura 38 - Nivel creat după prima reparare




Figura 39 - Nivel ce poate fi completat

Concluzii

În această lucrare am sugerat o metodă de a genera procedural conținutul jocului folosind rețele neuronale recurente de tip LSTM. Pe parcursul dezvoltării modelului am întâmpinat câteva dificultăți în ceea ce privește arhitectura rețelei precum și modul în care trebuie să reprezentăm datele pentru a antrena rețeaua cu succes. Deși am reușit să generăm nivele folosind modelul creat, astfel demonstrând faptul că este posibil să generăm nivele ce pot fi accesate în totalitatea încă de la începutul sesiunii de jucat folosind PCGML, tot a trebuit într-un final să reparăm nivelul creat datorită imposibilității de a-l finaliza cu succes. O altă problemă pe care am avut-o pe parcursul antrenării a fost numărul limitat de nivele din cadrul jocului original pe care l-am avut la dispoziție. Datorită acestui lucru se poate observa faptul că rețeaua tinde să genereze de mai multe ori aceleași structuri de conținut.

Ca și continuare a aplicației dorim să putem integra în procesul de antrenament factori precum timpul necesar pentru completarea nivelului sau feedback-ul jucătorului. Pentru integrarea timpului necesar de completare vom avea nevoie de un bot inteligent ce este capabil să joace jocul, iar la final să observăm cât de bine s-a descurcat, astfel putem antrena rețeaua neuronală în funcție de această valoare. În cazul în care observăm că bot-ul nu a fost în stare să termine cu succes nivelul respectiv, putem penaliza modelul folosind o funcție de fitness. Iar în ceea ce privește feedback-ul am dori ca pe viitor să avem acces la nivele ce au un anumit rating dat de către diverși jucători, astfel vom încerca să generăm pentru fiecare jucător în parte nivele ce seamănă ca și proprietăți cu nivelele ce au primit un rating pozitiv de la acesta.

O altă direcție pe care ar putea merge evoluția aplicației o reprezintă notarea gradului de credibilitate pe care îl oferă nivelul generat. Dorim să vedem cât de mult jucătorul consideră că nivelul generat este creat procedural și nu de către un om. Astfel putem să construim un model ce este capabil să detecteze caracteristicile nivelelor ce sunt considerate create de către calculator, și să-l folosim pentru a le scoate din procesul de generare.

În concluzie, consider că domeniul generării procedurale de conținut se află abia la început, și în viitor vom putea aplica aceste abordări nu doar pentru jocuri de tip platformă 2D, ci și pentru generarea mai complexă de conținut precum modele sau caractere 3D. Pentru a reuși acest lucru vom avea nevoie de seturi de date mult mai mari și de oameni ce doresc să participe în testarea și experimentarea conținutului generat.

Lista figurilor

Figura 1 - Labirint fără ieșire	6
Figura 2 - Exemplu de generare a lumii in Dwarf Fortress [6]	6
Figura 3- Modele de animale din No Man's Sky.....	7
Figura 4- Clarificarea unui segment al imaginii [8]	8
Figura 5 - Google Duplex.....	9
Figura 6 - Modelul perceptronului unui neuron	11
Figura 7- Rețea neuronală recursivă desfășurată [15]	12
Figura 8 - RNN desfășurat	13
Figura 9 - Rețea LSTM desfășurată	13
Figura 10 - Super Mario Bros publicat în 13 septembrie 1985 de către Nintendo Creative Department	15
Figura 11 – 1,2,3-grams [18].....	16
Figura 12 - Modul de generare al următorului element de conținut; verde reprezintă elementul de input și portocaliu cel de output [19]	16
Figura 13 - Specificarea parțială a unei cărți urmate de output	17
Figura 14 - Nivel din Super Mario Bros generat de lanțuri Markov multidimensionale	18
Figura 15- Detectarea nivelului ce conține o anumită porțiune de hartă folosind autoencodori	18
Figura 16 - A) Original B)Generat C) Reparat	19
Figura 17 - Aranjarea resurselor pe harta din StarCraft II	19
Figura 18 - Graful unui nivel Super Mario Bros din nori	20
Figura 19 - Diagrama cazurilor de utilizare	25
Figura 20 - Diagramă de secvență pentru deschiderea jocului.....	26

Figura 21 - Diagramă de secvență pentru antrenarea modelului.....	27
Figura 22 - Diagramă de componente a aplicației.....	29
Figura 23 - Diagrama de clase.....	30
Figura 24 - Pornire joc Lode Runner folosind Visual Studio	34
Figura 25 - Structura internă a jocului	34
Figura 26 - Ecranul de start al jocului Lode Runner	35
Figura 27 - Nivel Lode Runner și reprezentarea sa.....	36
Figura 28 - Apelarea scriptului python din C#.....	37
Figura 29 - Testare Web API	37
Figura 30 - Arhitectura rețelei neuronale	38
Figura 31 - Reprezentare nivel Lode Runner	38
Figura 32 - Modul de citire și de generare a nivelelor Lode Runner	39
Figura 33 - Analiza fiecărui batch de date	39
Figura 34 - Nivel generat folosind rețeaua neuronală	40
Figura 35 - Evaluarea funcției de loss.....	42
Figura 36 - Evaluarea acurateței modelului	42
Figura 37 - Primul nivel generat cu succes	43
Figura 38 - Nivel creat după prima reparație	43
Figura 39 - Nivel ce poate fi completat.....	43

Bibliografie

- [1] N. Shaker, J. Togelius și M. J. Nelson, *Procedural Content Generation in Games: A Textbook and an Overview of Current Research*, Springer, 2016.
- [2] A. M. Smith și M. Mateas, „Answer set programming for procedural content generation: A design space approach,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 3, pp. 187-200, 2011.
- [3] J. Togelius, G. N. Yannakakis, K. O. Stanley și C. Browne, „Search-based procedural content generation: A taxonomy and survey,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. III, pp. 172-186, 2011.
- [4] E. J. Aarseth, *Cybertext: perspectives on ergodic literature*, JHU Press, 1997.
- [5] T. Adams, „Dwarf Fortress,” *Game [Windows, Mac, Linux]*, Bay, vol. 12, 2006.
- [6] „Dwarf Fortress Online,” [Interactiv]. Available: <https://dfsuknfbz46oq.cloudfront.net/p/screenshots/dwarffortress-523e07c2-780b-4831-b95b-3ede852e96e3.png>.
- [7] S. Samit, „A brief tour of a tiny corner of No Man's Sky,” 1 Aprilie 2016. [Interactiv]. Available: <https://www.gamesradar.com/no-mans-sky-sheds-light-just-what-youll-do-its-vast-universe/>. [Accesat 14 Mai 2018].
- [8] X.-J. Mao, C. Shen și Y.-B. Yang, „Image restoration using convolutional auto-encoders with symmetric skip connections. arXiv preprint,” *arXiv preprint arXiv:1606.08921*, vol. 2, 2016.
- [9] S. J. Russell și P. Norvig, *Artificial intelligence: a modern approach*, Malaysia; Pearson Education Limited, 2016.
- [10] N. J. Nilsson, *Introduction to machine learning: An early draft of a proposed textbook*, USA; Stanford University, 1996.
- [11] I. Goodfellow, Y. Bengio, A. Courville și Y. Bengio, *Deep learning*, MIT press Cambridge, 2016.
- [12] B. Yegnanarayana, *Artificial neural networks*, PHI Learning Pvt. Ltd., 2009.
- [13] R. J. Schalkoff, *Artificial neural networks*, McGraw-Hill New York, 1997.
- [14] L. Medsker și L. Jain, „Recurrent neural networks,” *Design and Applications*, vol. 5, 2001.
- [15] „RNN,” [Interactiv]. Available: <http://www.wildml.com/wp-content/uploads/2015/09/rnn.jpg>.
- [16] F. A. Gers, J. Schmidhuber și F. Cummins, *Learning to forget: Continual prediction with LSTM*, IET, 1999.

- [17] S. M. Bros, *Instruction Booklet*, Nintendo, 1985.
- [18] S. Dahlskog, J. Togelius și M. J. Nelson, „Linear levels through n-grams,” în *Proceedings of the 18th International Academic MindTrek Conference: Media Business, Management, Content & Services*, 2014.
- [19] A. Summerville și M. Mateas, „Super mario as a string: Platformer level generation via lstms,” *arXiv preprint arXiv:1603.00930*, 2016.
- [20] M. Morgan, „RoboRosewater,” 2016. [Interactiv]. Available: <https://twitter.com/roborosewater?lang=en>.
- [21] W. Ching și S. a. N. M. Zhang, „On multi-dimensional Markov chain models,” *Pacific Journal of Optimization*, vol. 3, nr. 2, 2007.
- [22] S. Snodgrass și S. Ontanon, „Learning to generate video game maps using markov models,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 9, nr. 4, pp. 410-422, 2017.
- [23] R. Jain, A. Isaksen, C. Holmgard și J. Togelius, „Autoencoders for level generation, repair, and recognition,” în *Proceedings of the ICCG Workshop on Computational Creativity and Games*, 2016.
- [24] S. Lee, A. Isaksen, C. Holmgard și J. Togelius, „Predicting Resource Locations in Game Maps Using Deep Convolutional Neural Networks,” în *The Twelfth Annual AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment. AAAI*, 2016.
- [25] N. Shaker și M. Abou-Zleikha, „Alone We Can Do So Little, Together We Can Do So Much: A Combinatorial Approach for Generating Game Content,” *AIIDE*, vol. 14, pp. 1-1, 2014.
- [26] M. Guzdial și M. Riedl, „Game level generation from gameplay videos,” în *Twelfth Artificial Intelligence and Interactive Digital Entertainment Conference*, 2016.
- [27] S. Hung, „LodeRunner_TotalRecall,” 2017. [Interactiv]. Available: https://github.com/SimonHung/LodeRunner_TotalRecall.git.
- [28] R. a. G. J. a. M. J. a. F. H. Fielding, L. Masinter, P. Leach și T. Berners-Lee, *Hypertext transfer protocol--HTTP/1.1*, 1999.
- [29] C. Olah, „Understanding LSTM Networks,” 27 August 2015. [Interactiv]. Available: <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>.